Análisis Econométrico
Tarea 3

Magíster en Economía, Universidad Alberto Hurtado

Fecha de entrega: 22 de octubre de 2026 (al principio de la ayudantía)

Total: 100 puntos

Los ejercicios 3, 4 y 5 requieren estimar modelos con datos. Utilice R (u otro software estadístico) y adjunte su código. Reporte errores estándar robustos a heteroscedasticidad. Los datos están en el repositorio del curso: `wage2.dta` y `hprice2.dta`.

1. (20 puntos) Suponga homoscedasticidad. En clases vimos que, en ese caso, la varianza asintótica del estimador MCO es $\text{AVar}(\hat{\beta}) = \frac{\sigma^2}{N}\,\mathbb{E}(x_i x_i')^{-1}$.

   (a) (10 puntos) Considere el modelo de regresión simple

   $$y_i = \beta_0 + \beta_1 x_{1i} + u_i,$$

   donde $\mathbb{E}(u_i) = 0$, $\mathbb{E}(x_{1i}\,u_i) = 0$ y $\mathbb{E}(u_i^2|x_{1i}) = \sigma^2$. Utilice la fórmula anterior con $x_i = (1, x_{1i})'$ para demostrar que

   $$\text{AVar}(\hat{\beta}_1) = \frac{\sigma^2}{N}\frac{1}{\text{Var}(x_{1i})}.$$

   (b) (5 puntos) Considere ahora el modelo con dos variables explicativas

   $$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + v_i,$$

   donde $\mathbb{E}(v_i) = \mathbb{E}(x_{1i}\,v_i) = \mathbb{E}(x_{2i}\,v_i) = 0$ y $\mathbb{E}(v_i^2|x_{1i}, x_{2i}) = \sigma_v^2$. En clases vimos que

   $$\text{AVar}(\hat{\beta}_1) = \frac{\sigma_v^2}{N}\frac{1}{\text{Var}(r_{1i})},$$

   donde $\gamma_0 + \gamma_1 x_{2i}$ es el proyector lineal de x_{1i} en una constante y x_{2i}, y $r_{1i} = x_{1i} - \gamma_0 - \gamma_1 x_{2i}$ es su residuo. Demuestre que

   $$\text{Var}(r_{1i}) = \text{Var}(x_{1i})\,(1 - \rho^2),$$

   donde ρ es el coeficiente de correlación entre x_{1i} y x_{2i}: la covarianza dividida por el

producto de las desviaciones estándar,

$$\rho = \text{Corr}(x_{1i}, x_{2i}) = \frac{\text{Cov}(x_{1i}, x_{2i})}{\sqrt{\text{Var}(x_{1i})}\sqrt{\text{Var}(x_{2i})}}.$$

(c) (5 puntos) Explique cómo depende $\text{AVar}(\hat{\beta}_1)$ del tamaño de la muestra, de la varianza del error, de la varianza de x_1 y de la correlación entre x_1 y x_2. ¿Qué ocurre cuando $|\rho| \to 1$?

2. (10 puntos) Un estudio reciente ha encontrado que la tasa de mortalidad de las personas que duermen 7 horas por noche es menor que la tasa de mortalidad de aquellas personas que duermen 8 o más horas. El estudio utilizó 1,1 millones de observaciones de una muestra aleatoria de chilenos entre 30 y 102 años de edad. Cada persona en la muestra fue seguida por 4 años. La tasa de mortalidad para personas que duermen 7 horas fue calculada como el número de muertes durante los 4 años entre las personas que duermen 7 horas sobre el número de personas que duermen 7 horas en la muestra. Cálculos similares se realizaron para el resto de las categorías. En base a los resultados del estudio, ¿usted recomendaría a los chilenos que duermen 9 horas por noche reducir las horas de sueño a 7 horas por noche si quieren prolongar sus vidas? ¿Por qué o por qué no? Explique.

3. (20 puntos) Utilice los datos de `wage2.dta` del trabajo de Blackburn y Neumark (QJE, 1992): 935 hombres de entre 28 y 38 años en 1980. Las variables `wage` (salario mensual, en dólares), `married` (igual a 1 si está casado) y `urban` (igual a 1 si vive en una zona urbana) definen el modelo

$$\log(wage_i) = \beta_0 + \beta_1\, married_i + \beta_2\, urban_i + \beta_3\, married_i \times urban_i + u_i.$$

(a) (10 puntos) Estime el modelo. Escriba $\mathbb{E}(\log(wage)|married, urban)$ para los cuatro grupos (casado urbano, casado rural, soltero urbano y soltero rural) en función de los β's, e interprete cada uno de los coeficientes estimados.

(b) (5 puntos) Calcule la media muestral de $\log(wage)$ en cada grupo y verifique que coincide con el valor predicho por el modelo. Explique por qué.

(c) (5 puntos) Suponga que construye una dummy para cada uno de los cuatro grupos y estima la regresión de $\log(wage)$ en las cuatro dummies y una constante. ¿Qué ocurre? Explique.

4. (30 puntos) Utilice los datos de `wage2.dta` para estudiar los retornos de la educación. Además de las variables del ejercicio anterior, la base incluye `educ` (años de educación), `IQ` (resultado en un test de inteligencia), `exper` (años de experiencia laboral), `tenure` (años en el empleo actual) y `south` (igual a 1 si vive en el sur de EE.UU.).

(a) (5 puntos) Utilice un modelo de regresión simple log-nivel para estimar el efecto de un año más de educación (*educ*) en salarios (*wage*). Interprete los resultados. ¿Usted piensa que el coeficiente estimado mide una relación causal? Explique.

(b) (10 puntos) El modelo de regresión simple omite, entre otras cosas, la habilidad innata. En los datos existe una proxy de la habilidad innata: IQ. Antes de estimar, prediga si el coeficiente de *educ* aumentará o disminuirá al incluir IQ como variable explicativa adicional, y explique por qué. Luego estime el modelo con IQ, interprete el coeficiente de *educ* y compare con (a).

(c) (10 puntos) La fórmula del sesgo de variable omitida también se cumple en la muestra, reemplazando momentos poblacionales por momentos muestrales. Primero, compruebe este resultado en los datos: regrese IQ en *educ* y, en base a esa estimación y a lo obtenido en (b), recupere la pendiente estimada en (a). Segundo, demuestre analíticamente que este resultado se cumple siempre en la muestra.

(d) (5 puntos) Estime el efecto de la educación sobre los salarios controlando por IQ, *exper*, *tenure*, *married*, *south* y *urban*. Compare con los resultados de (a) y (b).

5. (20 puntos) Utilice los datos de `hprice2.dta` del trabajo de Harrison y Rubinfeld (JEEM, 1978) sobre el efecto de la contaminación en el precio de las viviendas: 506 comunidades del área metropolitana de Boston en 1970. Las variables son `price` (precio mediano de las viviendas, en dólares), `nox` (concentración de óxido de nitrógeno en el aire, en partes por 100 millones), `rooms` (número promedio de habitaciones), `dist` (distancia ponderada a cinco centros de empleo) y `stratio` (ratio estudiantes por profesor).

   (a) (5 puntos) Utilice un modelo de regresión simple log-log para estimar el efecto de un aumento en *nox* en *price*. Interprete los resultados. ¿Usted piensa que el coeficiente estimado mide una relación causal? Explique.

   (b) (5 puntos) Agregue las siguientes variables explicativas al modelo: *rooms*, log(*dist*) y *stratio*. Interprete la estimación del efecto de un aumento de la contaminación en el precio de las viviendas, compare con (a) y explique la diferencia.

   (c) (5 puntos) Obtenga la estimación del coeficiente de log(*nox*) del modelo en (b) utilizando la regresión particionada. Primero, guarde los residuos de una regresión de log(*nox*) en *rooms*, log(*dist*) y *stratio*. Segundo, regrese log(*price*) en esos residuos. Verifique que la estimación coincide con (b). No se preocupe por los errores estándar, sólo por las estimaciones puntuales.

   (d) (5 puntos) Compare el error estándar del coeficiente de log(*nox*) en (a) y en (b). Calcule la correlación muestral entre log(*nox*) y log(*dist*) y utilice la intuición del ejercicio 1 para explicar la diferencia.