

Análisis Econométrico

Teoría Asintótica

Ramiro de Elejalde

Facultad de Economía y Finanzas
Universidad Alberto Hurtado

Outline

Propiedades en muestras pequeñas de los estimadores

Propiedades asintóticas de los estimadores

Convergencia en probabilidad

Consistencia.

Ley (débil) de los grandes números (LGN)

Teorema de la función continua

Convergencia en distribución

Distribución asintótica normal.

Teorema de Slutsky

Teorema de la función continua (para $\xrightarrow{d}$.)

Método delta

Referencias: Cap. 7 y 8 Hansen (Introduction to Econometrics), y cap. 3 de Wooldridge.

- Dada una muestra aleatoria podemos calcular un estimador para “aproximar” los parámetros poblacionales de interés.
- Nos interesa que el estimador tenga “buenas” propiedades.
- En este curso nos enfocamos en las propiedades del estimador cuando $N \rightarrow \infty$, las **propiedades asintóticas**.
 1. Cuando N crece, la distribución del estimador se concentra alrededor del parámetro (**consistencia**)
 2. Cuando N crece la distribución del estimador (estandarizada) se acerca a una distribución normal (**distribución asintótica normal**)
- En esta unidad vamos a estudiar teoremas que nos permitan obtener las propiedades asintóticas de los estimadores que vamos a estudiar durante el curso.

Propiedades en muestras pequeñas de los estimadores

- **Parámetro:** Característica de la población de interés. Ejemplo: $\mu = \mathbb{E}(y)$

- **Parámetro:** Característica de la población de interés. Ejemplo: $\mu = \mathbb{E}(y)$
- **Muestra aleatoria:** Muestra de tamaño N de la población obtenida en forma aleatoria y con reemplazo $\{y_1, y_2, \dots, y_N\}$.

El muestreo aleatorio nos asegura que $y_1, y_2, \dots, y_N$ se distribuyen i.i.d.

- **Parámetro:** Característica de la población de interés. Ejemplo: $\mu = \mathbb{E}(y)$
- **Muestra aleatoria:** Muestra de tamaño N de la población obtenida en forma aleatoria y con reemplazo $\{y_1, y_2, \dots, y_N\}$.
El muestreo aleatorio nos asegura que $y_1, y_2, \dots, y_N$ se distribuyen i.i.d.
- **Estimador:** Un estadístico (función de las variables muestrales) que se utiliza para estimar un parámetro de interés. Ejemplo: Media muestral $\bar{y} = \frac{1}{N} \sum_{i=1}^N y_i$.

- **Parámetro:** Característica de la población de interés. Ejemplo: $\mu = \mathbb{E}(y)$
- **Muestra aleatoria:** Muestra de tamaño N de la población obtenida en forma aleatoria y con reemplazo $\{y_1, y_2, \dots, y_N\}$.
El muestreo aleatorio nos asegura que $y_1, y_2, \dots, y_N$ se distribuyen i.i.d.
- **Estimador:** Un estadístico (función de las variables muestrales) que se utiliza para estimar un parámetro de interés. Ejemplo: Media muestral $\bar{y} = \frac{1}{N} \sum_{i=1}^N y_i$.
- Recordar las propiedades de la varianza $\text{Var}(y)$
 - $\text{Var}(a + bx) = b^2 \text{Var}(x)$
 - $\text{Var}(bx + cy) = b^2 \text{Var}(x) + c^2 \text{Var}(y) + 2bc \text{Cov}(x, y)$

- **Insesgadez:** Un estimador $\hat{\theta}_N$ de un parámetro θ es **insesgado** si,

$$\mathbb{E}(\hat{\theta}_N) = \theta \text{ para todo } N.$$

- **Eficiencia:** Un estimador $\hat{\theta}_N$ de un parámetro θ es **eficiente** si,

$$\text{Var}(\hat{\theta}_N) \leq \text{Var}(\tilde{\theta}_N),$$

para todo $\tilde{\theta}_N$ en una familia de estimadores de θ con ciertas propiedades (por ejemplo, insesgados y lineales).

Ejemplo: Media muestral

- Dada una muestra i.i.d. $\{y_1, \dots, y_N\}$ con $\mathbb{E}(y_i) = \mu$ y $\text{Var}(y_i) = \sigma^2$
- Parámetro: μ .
- Estimador: **media muestral**

$$\bar{y} = \frac{1}{N} \sum_i y_i.$$

Ejemplo: Media muestral

- Insesgadez: $\mathbb{E}(\bar{y}) = \mu$

Ejemplo: Media muestral

Solución: Por linealidad de la esperanza,

$$\mathbb{E}(\bar{y}) = \mathbb{E}\left(\frac{1}{N} \sum_i y_i\right) = \frac{1}{N} \sum_i \mathbb{E}(y_i) = \frac{1}{N}(N\mu) = \mu.$$

Ejemplo: Media muestral

- Eficiencia: $\text{Var}(\bar{y}) = \frac{\sigma^2}{N}$

Ejemplo: Media muestral

Solución:

$$\text{Var}(\bar{y}) = \text{Var}\left(\frac{1}{N} \sum_i y_i\right) = \frac{1}{N^2} \sum_i \text{Var}(y_i) = \frac{1}{N^2} (N\sigma^2) = \frac{\sigma^2}{N},$$

donde usamos independencia ($\text{Cov}(y_i, y_j) = 0$ para $i \neq j$) y que las y_i son idénticamente distribuidas ($\text{Var}(y_i) = \sigma^2$ para todo i).


Propiedades asintóticas de los estimadores

Convergencia de variables aleatorias

- El análisis asintótico se ocupa de estudiar la **convergencia de una secuencia de variables aleatorias**.
- Cuando aplicamos estos conceptos a econometría, las variables aleatorias son estimadores cuya distribución depende del tamaño de la muestra N y buscamos la distribución del estimador cuando $N \rightarrow \infty$.

Ejemplos


- Una secuencia determinística puede ser $\{a_N\}_{N=1}^{\infty}$ donde $a_N = \{2 + \frac{1}{N}\}$.



Ejemplos





- Una secuencia de variables aleatorias puede ser

$$z_N = \begin{cases} 0 & \text{con probabilidad } 1 - \frac{1}{N}, \\ N & \text{con probabilidad } \frac{1}{N}, \end{cases}$$



Ejemplos

La media muestral para una muestra de tamaño N : $\bar{y}_N$. La secuencia es $\{\bar{y}_1, \bar{y}_2, \dots\}$ – por ejemplo, para $y_i \sim \text{Bernoulli}(p = 0.78)$:



Convergencia para secuencias determinísticas

- Una secuencia determinística a_N **converge** a a cuando $N \rightarrow \infty$ si para todo $\delta > 0$ existe $N_\delta < \infty$ tal que,

$$|a_N - a| \leq \delta \quad \text{para todo } N \geq N_\delta.$$

- Notación: $a_N \rightarrow a$ ó $\lim a_N = a$

Convergencia para secuencias determinísticas

- **Ejemplo:** La secuencia determinística $\{a_N\}_{N=1}^{\infty}$ donde $a_N = \{2 + \frac{1}{N}\}$ converge a $\lim_{N \rightarrow \infty} a_N = 2$.

Solución formal: Dado $\delta > 0$, sea $N_\delta = 1/\delta$. Para todo $N \geq N_\delta$,

$$|a_N - 2| = \left| \frac{1}{N} \right| = \frac{1}{N} \leq \frac{1}{N_\delta} = \delta.$$

Por lo tanto $a_N \rightarrow 2$.

Convergencia en probabilidad

- Una variable aleatoria z_N **converge en probabilidad** a una constante c cuando $N \rightarrow \infty$ si para todo $\delta > 0$,

$$\lim_{N \rightarrow \infty} \Pr(|z_N - c| \leq \delta) = 1$$

- Notación: $z_N \xrightarrow{p} c$ ó $\text{plim } z_N = c$

- **Ejemplo:** Calcule la convergencia en probabilidad de z_N

$$z_N = \begin{cases} 0 & \text{con probabilidad } 1 - \frac{1}{N}, \\ N & \text{con probabilidad } \frac{1}{N}, \end{cases}$$

- **Ejemplo:** Calcule la convergencia en probabilidad de z_N

$$z_N = \begin{cases} 0 & \text{con probabilidad } 1 - \frac{1}{N}, \\ N & \text{con probabilidad } \frac{1}{N}, \end{cases}$$

- Respuesta: $z_N \xrightarrow{P} 0$.

Solución formal: Dado $\delta > 0$, para $N > \delta$ se tiene $\{z_N = N\} \implies |z_N - 0| > \delta$, por lo tanto

$$\Pr(|z_N - 0| \leq \delta) = \Pr(z_N = 0) = 1 - \frac{1}{N} \xrightarrow[N \rightarrow \infty]{} 1.$$





Como esto vale para todo $\delta > 0$, $z_N \xrightarrow{P} 0$.

- **Consistencia:** Un estimador $\hat{\theta}_N$ de un parámetro θ es **consistente** si,

$$\hat{\theta}_N \xrightarrow{p} \theta \text{ cuando } N \rightarrow \infty.$$

Ejemplo: Bernoulli con $p=0.78$

Simulación: $y_i \sim \text{Bernoulli}(p = 0.78)$ i.i.d.; distribución muestral de $\bar{y}_N$ para $N = 2, 5, 25, 100$. Al crecer N , se concentra alrededor de $p = 0.78$ (consistencia).



Ley (débil) de los grandes números (LGN)

- Dada una muestra i.i.d. de tamaño N , si $\mathbb{E}|y| < \infty$, entonces cuando $N \rightarrow \infty$,

$$\frac{1}{N} \sum_{i=1}^N y_i \xrightarrow{p} \mathbb{E}(y).$$

Ley (débil) de los grandes números (LGN)

- Dada una muestra i.i.d. de tamaño N , si $\mathbb{E}|y| < \infty$, entonces cuando $N \rightarrow \infty$,

$$\frac{1}{N} \sum_{i=1}^N y_i \xrightarrow{p} \mathbb{E}(y).$$

- Extensión para vectores aleatorios. Definimos a $\mathbf{y} : \mathbb{R}^m \times 1$. Dada una muestra i.i.d. de tamaño N , si $\mathbb{E}|\mathbf{y}| < \infty$, entonces cuando $N \rightarrow \infty$,

$$\frac{1}{N} \sum_{i=1}^N \mathbf{y}_i \xrightarrow{p} \mathbb{E}(\mathbf{y}).$$

- Media muestral

$$\bar{y} = \frac{1}{N} \sum_{i=1}^N y_i \xrightarrow{p} \mu$$

donde $\mu = \mathbb{E}(y)$.

Ejemplos: solución

Solución: Aplicando la LGN a la muestra i.i.d. $\{y_i\}$,

$$\bar{y} = \frac{1}{N} \sum_{i=1}^N y_i \xrightarrow{p} \mathbb{E}(y) = \mu.$$

- Media muestral de y_i^2

$$\frac{1}{N} \sum_{i=1}^N y_i^2 \xrightarrow{p} \mathbb{E}(y^2)$$

Ejemplos: solución

Solución: $\{y_i^2\}$ también es una muestra i.i.d. (función de una muestra i.i.d.).
Aplicando la LGN a $\{y_i^2\}$,

$$\frac{1}{N} \sum_{i=1}^N y_i^2 \xrightarrow{p} \mathbb{E}(y^2).$$

Teorema de la función continua

- Si $z_N \xrightarrow{p} c$ cuando $N \rightarrow \infty$, y $g(\cdot)$ es continua en c , entonces

$$g(z_N) \xrightarrow{p} g(c) \text{ cuando } N \rightarrow \infty.$$

- **Varianza muestral**

$$\begin{aligned} S^2 &= \frac{1}{N} \sum_{i=1}^N (y_i - \bar{y})^2 \\ &= \frac{1}{N} \sum_{i=1}^N y_i^2 - \bar{y}^2 \xrightarrow{p} \sigma^2, \end{aligned}$$

donde $\sigma^2 = \text{Var}(y)$.

Ejemplos: solución

Solución: Por LGN, $\bar{y} \xrightarrow{P} \mu$ y $\frac{1}{N} \sum_i y_i^2 \xrightarrow{P} \mathbb{E}(y^2)$. La función $g(a, b) = a - b^2$ es continua, luego por el teorema de la función continua,

$$\frac{1}{N} \sum_i y_i^2 - \bar{y}^2 = g\left(\frac{1}{N} \sum_i y_i^2, \bar{y}\right) \xrightarrow{P} g(\mathbb{E}(y^2), \mu) = \mathbb{E}(y^2) - \mu^2 = \sigma^2.$$

- Desviación estándar muestral: $S \xrightarrow{p} \sigma$

Ejemplos: solución

Solución: Ya vimos $S^2 \xrightarrow{p} \sigma^2$. La función $g(x) = \sqrt{x}$ es continua para $x \geq 0$, luego por el teorema de la función continua,

$$S = \sqrt{S^2} = g(S^2) \xrightarrow{p} g(\sigma^2) = \sqrt{\sigma^2} = \sigma.$$

Diferencias entre insesgadez y consistencia

- **Insesgadez no implica consistencia.**

Ejemplo: $\tilde{y} = y_1$

Diferencias entre insesgadez y consistencia

- **Insesgadez no implica consistencia.**

Ejemplo: $\tilde{y} = y_1$

- **Consistencia no implica insesgadez.**

Ejemplo: Varianza muestral S^2

Diferencias entre insesgadez y consistencia

- **Insesgadez no implica consistencia.**

Ejemplo: $\tilde{y} = y_1$

- **Consistencia no implica insesgadez.**

Ejemplo: Varianza muestral S^2

- Teorema: Si $\lim_{N \rightarrow \infty} \mathbb{E}(\hat{\theta}_N) = \theta$ y $\lim_{N \rightarrow \infty} \text{Var}(\hat{\theta}_N) = 0$, entonces $\hat{\theta}_N \xrightarrow{p} \theta$ cuando $N \rightarrow \infty$.

Diferencias entre insesgadez y consistencia

- **Insesgadez no implica consistencia.**

Ejemplo: $\tilde{y} = y_1$

- **Consistencia no implica insesgadez.**

Ejemplo: Varianza muestral S^2

- Teorema: Si $\lim_{N \rightarrow \infty} \mathbb{E}(\hat{\theta}_N) = \theta$ y $\lim_{N \rightarrow \infty} \text{Var}(\hat{\theta}_N) = 0$, entonces $\hat{\theta}_N \xrightarrow{p} \theta$ cuando $N \rightarrow \infty$.
- **Consistencia no implica insesgadez asintótica.**

Diferencias entre insesgadez y consistencia

- **Insesgadez no implica consistencia.**

Ejemplo: $\tilde{y} = y_1$

- **Consistencia no implica insesgadez.**

Ejemplo: Varianza muestral S^2

- Teorema: Si $\lim_{N \rightarrow \infty} \mathbb{E}(\hat{\theta}_N) = \theta$ y $\lim_{N \rightarrow \infty} \text{Var}(\hat{\theta}_N) = 0$, entonces $\hat{\theta}_N \xrightarrow{P} \theta$ cuando $N \rightarrow \infty$.

- **Consistencia no implica insesgadez asintótica.**

Ejemplo donde consistencia no implica insesgadez asintótica: $z_N = 0$ con probabilidad $1 - 1/N$, y $z_N = N$ con probabilidad $1/N$.


- Dada una variable aleatoria con función de distribución $F_N(u) = \Pr(z_N \leq u)$. z_N **converge en distribución** a z cuando $N \rightarrow \infty$ si para todo u en donde $F(u) = \Pr(z \leq u)$ es continua,

$$F_N(u) \rightarrow F(u) \text{ cuando } N \rightarrow \infty.$$

Convergencia en distribución

- Ejemplo: Demuestre que

$$F_N(u) = \frac{\exp(Nu)}{1 + \exp(Nu)} \rightarrow F(u) = \begin{cases} 0 & \text{si } u < 0, \\ 1 & \text{si } u \geq 0. \end{cases}$$



Convergencia en distribución: solución

- Si $u > 0$: $Nu \rightarrow \infty$, luego $\exp(Nu) \rightarrow \infty$ y

$$F_N(u) = \frac{1}{1 + \exp(-Nu)} \rightarrow \frac{1}{1 + 0} = 1.$$

- Si $u < 0$: $Nu \rightarrow -\infty$, luego $\exp(Nu) \rightarrow 0$ y $F_N(u) \rightarrow \frac{0}{1+0} = 0$.
- Si $u = 0$: $F_N(0) = \frac{1}{2}$ para todo N , pero esto **no importa**: $u = 0$ es un punto de discontinuidad de F (salta de 0 a 1 ahí), y la definición de convergencia en distribución sólo exige $F_N(u) \rightarrow F(u)$ en los puntos de continuidad de F .

Por lo tanto $F_N(u) \rightarrow F(u)$ para todo $u \neq 0$, es decir $z_N \xrightarrow{d} z$ donde z tiene distribución degenerada en 0 (i.e. $z = 0$ con probabilidad 1). Cuando el límite es una constante, convergencia en distribución implica convergencia en probabilidad a esa misma constante (lo vemos formalmente en la próxima slide), así que esto también implica $z_N \xrightarrow{p} 0$.

- Dada una variable aleatoria con función de distribución $F_N(u) = \Pr(z_N \leq u)$. z_N **converge en distribución** a z cuando $N \rightarrow \infty$ si para todo u en donde $F(u) = \Pr(z \leq u)$ es continua,

$$F_N(u) \rightarrow F(u) \text{ cuando } N \rightarrow \infty.$$

- Notación: $z_N \xrightarrow{d} z$.

Convergencia en distribución

- Dada una variable aleatoria con función de distribución $F_N(u) = \Pr(z_N \leq u)$. z_N **converge en distribución** a z cuando $N \rightarrow \infty$ si para todo u en donde $F(u) = \Pr(z \leq u)$ es continua,

$$F_N(u) \rightarrow F(u) \text{ cuando } N \rightarrow \infty.$$

- Notación: $z_N \xrightarrow{d} z$.
- Convergencia en probabilidad implica convergencia en distribución:
 $z_N \xrightarrow{p} z \implies z_N \xrightarrow{d} z$.

Convergencia en distribución

- Dada una variable aleatoria con función de distribución $F_N(u) = \Pr(z_N \leq u)$. z_N **converge en distribución** a z cuando $N \rightarrow \infty$ si para todo u en donde $F(u) = \Pr(z \leq u)$ es continua,

$$F_N(u) \rightarrow F(u) \text{ cuando } N \rightarrow \infty.$$

- Notación: $z_N \xrightarrow{d} z$.
- Convergencia en probabilidad implica convergencia en distribución:
 $z_N \xrightarrow{p} z \implies z_N \xrightarrow{d} z$.
- Si z_N converge en distribución a una constante entonces z_N converge en probabilidad a dicha constante: $z_N \xrightarrow{d} c \implies z_N \xrightarrow{p} c$

- Un estimador $\hat{\theta}_N$ de un parámetro θ se distribuye $\sqrt{N}$ -**asintóticamente normal** si,

$$\sqrt{N}(\hat{\theta}_N - \theta) \xrightarrow{d} \text{Normal}(0, V),$$

donde V es la varianza asintótica de $\sqrt{N}(\hat{\theta}_N - \theta)$ y se denota $\text{AVar}(\sqrt{N}(\hat{\theta}_N - \theta)) = V$.

Distribución asintótica normal

- Decimos $\hat{\theta}_N \overset{a}{\sim} \text{Normal}(\theta, V/N)$ donde $\text{AVar}(\hat{\theta}_N) = V/N$ es la **varianza asintótica de $\hat{\theta}_N$** y $\text{sd}(\hat{\theta}_N) = V^{1/2}/\sqrt{N}$ es la **desviación estándar asintótica de $\hat{\theta}_N$** .

Distribución asintótica normal

- Decimos $\hat{\theta}_N \overset{a}{\sim} \text{Normal}(\theta, V/N)$ donde $\text{AVar}(\hat{\theta}_N) = V/N$ es la **varianza asintótica de $\hat{\theta}_N$** y $\text{sd}(\hat{\theta}_N) = V^{1/2}/\sqrt{N}$ es la **desviación estándar asintótica de $\hat{\theta}_N$** .
- Si no conocemos V ¿cómo calculamos el $\text{sd}(\hat{\theta}_N)$?

Distribución asintótica normal

- Decimos $\hat{\theta}_N \overset{a}{\sim} \text{Normal}(\theta, V/N)$ donde $\text{AVar}(\hat{\theta}_N) = V/N$ es la **varianza asintótica de $\hat{\theta}_N$** y $\text{sd}(\hat{\theta}_N) = V^{1/2}/\sqrt{N}$ es la **desviación estándar asintótica de $\hat{\theta}_N$** .
- Si no conocemos V ¿cómo calculamos el $\text{sd}(\hat{\theta}_N)$?
- Si tenemos un estimador consistente de V , $\hat{V}_N \xrightarrow{P} V$, utilizamos $\text{se}(\hat{\theta}_N) = \hat{V}_N^{1/2}/\sqrt{N}$ y lo llamamos **error estándar asintótico de $\hat{\theta}_N$**

Lindeberg-Lévy Teorema Central del límite (TCL)

- Dada una muestra i.i.d. de tamaño N , si $\text{Var}(y) < \infty$, entonces cuando $N \rightarrow \infty$,

$$\sqrt{N} \frac{1}{N} \sum_{i=1}^N (y_i - \mathbb{E}(y)) \xrightarrow{d} \text{Normal}(0, \text{Var}(y)).$$

Lindeberg-Lévy Teorema Central del límite (TCL)





- Dada una muestra i.i.d. de tamaño N , si $\text{Var}(y) < \infty$, entonces cuando $N \rightarrow \infty$,

$$\sqrt{N} \frac{1}{N} \sum_{i=1}^N (y_i - \mathbb{E}(y)) \xrightarrow{d} \text{Normal}(0, \text{Var}(y)).$$





- También se suele escribir:

$$\sqrt{N} \left(\frac{1}{N} \sum_{i=1}^N y_i - \mathbb{E}(y) \right) \xrightarrow{d} \text{Normal}(0, \text{Var}(y)).$$

Ejemplo: Bernoulli con $p=0.78$



Ejemplo: Distribución muestral de $\sqrt{N}(\hat{p} - p)/\sqrt{p(1-p)}$ para Bernoulli con $p=0.78$



Lindeberg-Lévy Teorema Central del límite (TCL)

- Extensión para vectores aleatorios. Definimos a $\mathbf{y} : \mathbb{R}^m \times 1$ y $\text{Var}(\mathbf{y}) = \mathbb{E}[(\mathbf{y} - \mu)(\mathbf{y} - \mu)']$. Dada una muestra i.i.d. de tamaño N , si $\mathbb{E}|\mathbf{y}| < \infty$, entonces cuando $N \rightarrow \infty$,

$$\sqrt{N} \frac{1}{N} \sum_{i=1}^N (\mathbf{y}_i - \mathbb{E}(\mathbf{y})) \xrightarrow{d} \text{Normal}(0, \text{Var}(\mathbf{y})).$$

- Media muestral

$$\sqrt{N}(\bar{y} - \mu) \xrightarrow{d} \text{Normal}(0, \sigma^2).$$

- Media muestral

$$\sqrt{N}(\bar{y} - \mu) \xrightarrow{d} \text{Normal}(0, \sigma^2).$$

- Decimos

$$\bar{y} \overset{a}{\sim} \text{Normal}(\mu, \sigma^2/N),$$

$$sd(\bar{y}) = \sigma/\sqrt{N}.$$

- Media muestral

$$\sqrt{N}(\bar{y} - \mu) \xrightarrow{d} \text{Normal}(0, \sigma^2).$$

- Decimos

$$\bar{y} \overset{a}{\sim} \text{Normal}(\mu, \sigma^2/N),$$

$$sd(\bar{y}) = \sigma/\sqrt{N}.$$

- Para **vectores** tenemos un resultado similar

$$\sqrt{N}(\bar{\mathbf{y}} - \boldsymbol{\mu}) \xrightarrow{d} \text{Normal}(0, \boldsymbol{\Sigma}),$$

Teorema de Slutsky

- Si $z_N \xrightarrow{d} z$ y $c_N \xrightarrow{p} c$ donde c es una constante, cuando $N \rightarrow \infty$, entonces
 1. $c_N + z_N \xrightarrow{d} c + z$,
 2. $c_N z_N \xrightarrow{d} c z$,
 3. $\frac{z_N}{c_N} \xrightarrow{d} \frac{z}{c}$ si $c \neq 0$.

Teorema de Slutsky

- **Ejemplos:** Suponga que $z_N \xrightarrow{d} z \sim \text{Normal}(\mu, \sigma^2)$. Encuentre la distribución asintótica de
 1. $c_N + z_N$,
 2. $c_N z_N$,
 3. $\frac{z_N}{c_N}$.

Teorema de Slutsky

- **Ejemplos:** Suponga que $z_N \xrightarrow{d} z \sim \text{Normal}(\mu, \sigma^2)$ entonces
 1. Por Slutsky (suma), $c_N + z_N \xrightarrow{d} c + z$; como $c + z$ es una transformación lineal de $z \sim \text{Normal}(\mu, \sigma^2)$, $c + z \sim \text{Normal}(c + \mu, \sigma^2)$.
 2. Por Slutsky (producto), $c_N z_N \xrightarrow{d} cz$; $cz \sim \text{Normal}(c\mu, c^2\sigma^2)$.
 3. Por Slutsky (cociente, $c \neq 0$), $\frac{z_N}{c_N} \xrightarrow{d} \frac{z}{c}$; $\frac{z}{c} \sim \text{Normal}(\frac{\mu}{c}, \frac{\sigma^2}{c^2})$.

Ejemplo: Media muestral con varianza muestral

- Para y escalar

$$\sqrt{N} \frac{(\bar{y} - \mu)}{\sqrt{S^2}} \xrightarrow{d} \text{Normal}(0, 1).$$

Solución: Escribimos $\sqrt{N} \frac{(\bar{y} - \mu)}{S}$. Por el TCL, $\sqrt{N}(\bar{y} - \mu) \xrightarrow{d} \text{Normal}(0, \sigma^2)$; y ya vimos $S \xrightarrow{P} \sigma$. Por Slutsky (cociente, con $\sigma \neq 0$),

$$\sqrt{N} \frac{(\bar{y} - \mu)}{S} \xrightarrow{d} \frac{\text{Normal}(0, \sigma^2)}{\sigma} = \text{Normal}(0, 1).$$

- **Varianza muestral**

$$\sqrt{N}(S^2 - \sigma^2) \xrightarrow{d} \text{Normal}(0, \mu_4 - (\sigma^2)^2)$$

donde $\mu_4 = \mathbb{E}[(y - \mathbb{E}(y))^4]$.

Ejemplo: solución

Solución: Descomponemos

$$\begin{aligned} S^2 &= \frac{1}{N} \sum_i (y_i - \bar{y})^2 = \frac{1}{N} \sum_i (y_i - \mu - (\bar{y} - \mu))^2 \\ &= \frac{1}{N} \sum_i (y_i - \mu)^2 - (\bar{y} - \mu)^2. \end{aligned}$$



Por lo tanto

$$\sqrt{N}(S^2 - \sigma^2) = \sqrt{N} \left[\frac{1}{N} \sum_i (y_i - \mu)^2 - \sigma^2 \right] - \sqrt{N}(\bar{y} - \mu)(\bar{y} - \mu).$$

El primer término converge en distribución a $\text{Normal}(0, \mu_4 - (\sigma^2)^2)$ aplicando el TCL a la muestra i.i.d. $\{(y_i - \mu)^2\}$ (media σ^2 , varianza $\mu_4 - (\sigma^2)^2$). El segundo término es el producto de $\sqrt{N}(\bar{y} - \mu) \xrightarrow{d} \text{Normal}(0, \sigma^2)$ por $(\bar{y} - \mu) \xrightarrow{p} 0$, que converge en probabilidad a 0 por Slutsky. Sumando ambos términos (Slutsky), $\sqrt{N}(S^2 - \sigma^2) \xrightarrow{d} \text{Normal}(0, \mu_4 - (\sigma^2)^2)$.

Repaso de estadística: Funciones de distribución

- **Normal univariante:** $x \sim \text{Normal}(\mu, \sigma^2)$; normal estandarizada: $z \sim \text{Normal}(0, 1)$
- **Normal multivariante:** $\mathbf{x} \sim \text{Normal}(\mu, \Sigma)$ donde $\mathbf{x} : K \times 1$, $\mu : K \times 1$ y $\Sigma : K \times K$.



- **Normal univariante:** $x \sim \text{Normal}(\mu, \sigma^2)$; normal estandarizada: $z \sim \text{Normal}(0, 1)$
- **Normal multivariante:** $\mathbf{x} \sim \text{Normal}(\mu, \Sigma)$ donde $\mathbf{x} : K \times 1$, $\mu : K \times 1$ y $\Sigma : K \times K$.

Propiedades:

- Dada $\mathbf{x} \sim \text{Normal}(\mu, \Sigma)$ y $a : K \times 1$ entonces $a'\mathbf{x} \sim \text{Normal}(a'\mu, a'\Sigma a)$.
- Dada $\mathbf{x} \sim \text{Normal}(\mu, \Sigma)$ y $A : Q \times K$ entonces $A\mathbf{x} \sim \text{Normal}(A\mu, A\Sigma A')$.
- Dada $\mathbf{x} \sim \text{Normal}(\mu, \Sigma)$. Entonces $\{x_1, \dots, x_K\}$ son independientes si y sólo si Σ es diagonal.

Repaso de estadística: Funciones de distribución

- Ejemplo: Normal bivalente. Obtener función de distribución de $x + y$.

Solución: Sea $\mathbf{x} = (x, y)' \sim \text{Normal}(\mu, \Sigma)$ con $\mu = (\mu_x, \mu_y)'$ y $\Sigma = \begin{pmatrix} \sigma_x^2 & \sigma_{xy} \\ \sigma_{xy} & \sigma_y^2 \end{pmatrix}$.

Tomando $a = (1, 1)'$, $x + y = a'\mathbf{x}$, y por la propiedad anterior,

$$x + y = a'\mathbf{x} \sim \text{Normal}(a'\mu, a'\Sigma a) = \text{Normal}(\mu_x + \mu_y, \sigma_x^2 + \sigma_y^2 + 2\sigma_{xy}).$$

Repaso de álgebra de matrices

- Dado $A \geq 0$ (semidefinida positiva) podemos encontrar B tal que $A = BB'$. Llamamos a $B = A^{1/2}$ (por razones obvias).
- Propiedad: $B^{-1}AB'^{-1} = B^{-1}BB'B'^{-1} = I$. Llamamos a $B^{-1} = A^{-1/2}$.
- Para resumir: dado $A \geq 0$ siempre podemos definir una matriz $A^{-1/2}$ que verifica $A^{-1/2}AA^{-1/2} = I$.

Ejemplo

- Ejemplo: Si $\mathbf{x} \sim \text{Normal}(0, \Sigma)$ entonces $\Sigma^{-1/2}\mathbf{x} \sim \text{Normal}(0, I_K)$.

Solución: Tomando $A = \Sigma^{-1/2}$ en la propiedad $A\mathbf{x} \sim \text{Normal}(A\mu, A\Sigma A')$,

$$\Sigma^{-1/2}\mathbf{x} \sim \text{Normal}\left(\Sigma^{-1/2} \cdot 0, \Sigma^{-1/2}\Sigma\Sigma'^{-1/2}\right) = \text{Normal}(0, I_K),$$

donde $\Sigma^{-1/2}\Sigma\Sigma'^{-1/2} = I_K$ por construcción de $\Sigma^{-1/2}$ (repaso de álgebra de matrices).

Ejemplo: Media muestral con varianza muestral

- Para $\mathbf{y} : K \times 1$

$$\sqrt{N}\hat{\Sigma}^{-1/2}(\bar{\mathbf{y}} - \boldsymbol{\mu}) \xrightarrow{d} \text{Normal}(0, I_K).$$

donde $\text{Var}(\mathbf{y}) = \boldsymbol{\Sigma}$ y $\hat{\Sigma} \xrightarrow{p} \boldsymbol{\Sigma}$.

Solución: Por el TCL, $\sqrt{N}(\bar{\mathbf{y}} - \boldsymbol{\mu}) \xrightarrow{d} \text{Normal}(0, \boldsymbol{\Sigma})$. Como $\hat{\Sigma} \xrightarrow{p} \boldsymbol{\Sigma}$ y la raíz inversa es continua, $\hat{\Sigma}^{-1/2} \xrightarrow{p} \boldsymbol{\Sigma}^{-1/2}$ (teorema de la función continua). Por Slutsky,

$$\sqrt{N}\hat{\Sigma}^{-1/2}(\bar{\mathbf{y}} - \boldsymbol{\mu}) \xrightarrow{d} \boldsymbol{\Sigma}^{-1/2} \text{Normal}(0, \boldsymbol{\Sigma}) = \text{Normal}(0, \boldsymbol{\Sigma}^{-1/2}\boldsymbol{\Sigma}\boldsymbol{\Sigma}'^{-1/2}) = \text{Normal}(0, I_K),$$

usando el resultado que vimos anteriormente ($\boldsymbol{\Sigma}^{-1/2}\boldsymbol{\Sigma}\boldsymbol{\Sigma}'^{-1/2} = I_K$).


Teorema de la función continua (para $\xrightarrow{d}$)

- Si $z_N \xrightarrow{d} z$ cuando $N \rightarrow \infty$ y $g : \mathbb{R}^m \rightarrow \mathbb{R}^k$ tiene un conjunto de puntos de discontinuidad D_g tales que $\Pr(z \in D_g) = 0$, entonces

$$g(z_N) \xrightarrow{d} g(z) \text{ cuando } N \rightarrow \infty.$$

Repaso de estadística: Funciones de distribución

- **Chi-cuadrado** χ_Q^2
- Dadas $\{z_1, \dots, z_Q\}$ independientes y $z_j \sim \text{Normal}(0, 1)$ entonces $y = \sum_{j=1}^Q z_j^2$ se distribuye como una χ_Q^2 .



Ejemplo

- Para y escalar

$$N \frac{(\bar{y} - \mu)^2}{S^2} \xrightarrow{d} \chi_1^2.$$

Solución: Ya vimos $\sqrt{N}(\bar{y} - \mu)/S \xrightarrow{d} \text{Normal}(0, 1)$. La función $g(x) = x^2$ es continua, luego por el teorema de la función continua (para $\xrightarrow{d}$),

$$N \frac{(\bar{y} - \mu)^2}{S^2} = \left(\sqrt{N} \frac{\bar{y} - \mu}{S} \right)^2 \xrightarrow{d} z^2, \quad z \sim \text{Normal}(0, 1),$$

y $z^2 \sim \chi_1^2$ por definición (suma de un cuadrado de una normal estándar).

Ejemplo

- Para $\mathbf{y} : K \times 1$

$$N(\bar{\mathbf{y}} - \boldsymbol{\mu})' \hat{\boldsymbol{\Sigma}}^{-1} (\bar{\mathbf{y}} - \boldsymbol{\mu}) \xrightarrow{d} \chi_K^2.$$

Solución: Sea $\mathbf{w}_N = \sqrt{N} \hat{\boldsymbol{\Sigma}}^{-1/2} (\bar{\mathbf{y}} - \boldsymbol{\mu}) \xrightarrow{d} \mathbf{w} \sim \text{Normal}(0, I_K)$ (que vimos anteriormente). Como $g(\mathbf{z}) = \mathbf{z}'\mathbf{z}$ es continua, por el teorema de la función continua,

$$\mathbf{w}_N' \mathbf{w}_N = N(\bar{\mathbf{y}} - \boldsymbol{\mu})' \hat{\boldsymbol{\Sigma}}^{-1} (\bar{\mathbf{y}} - \boldsymbol{\mu}) \xrightarrow{d} \mathbf{w}' \mathbf{w},$$

usando $\hat{\boldsymbol{\Sigma}}^{-1/2'} \hat{\boldsymbol{\Sigma}}^{-1/2} = \hat{\boldsymbol{\Sigma}}^{-1}$, y $\mathbf{w}' \mathbf{w} = \sum_{k=1}^K w_k^2 \sim \chi_K^2$ por definición, ya que $w_1, \dots, w_K$ son independientes $\text{Normal}(0, 1)$.

Método delta

- Si $\sqrt{N}(\hat{\theta}_N - \theta) \xrightarrow{d} \text{Normal}(0, V)$ donde θ es $m \times 1$, y $g(\theta) : \mathbb{R}^m \rightarrow \mathbb{R}^k$ es continuamente diferenciable en la vecindad de θ , entonces cuando $N \rightarrow \infty$

$$\sqrt{N}(g(\hat{\theta}_N) - g(\theta)) \xrightarrow{d} \text{Normal}(0, G'VG),$$

donde $G(z) = \frac{\partial}{\partial z}g(z)'$ y $G = G(\theta)$.

- **Media muestral al cuadrado:** $\bar{y}^2$

$$\sqrt{N}(\bar{y}^2 - \mu^2) \xrightarrow{d} \text{Normal}(0, 4\mu^2\sigma^2).$$

Solución: Por el TCL, $\sqrt{N}(\bar{y} - \mu) \xrightarrow{d} \text{Normal}(0, \sigma^2)$. Aplicamos el método delta con $g(\theta) = \theta^2$, $G = g'(\mu) = 2\mu$,

$$\sqrt{N}(\bar{y}^2 - \mu^2) = \sqrt{N}(g(\bar{y}) - g(\mu)) \xrightarrow{d} \text{Normal}(0, G^2\sigma^2) = \text{Normal}(0, 4\mu^2\sigma^2).$$

Nota: Diferencia con la distribución asintótica de $N(\bar{y} - \mu)^2/S^2 \xrightarrow{d} \chi_1^2$.

- **Efecto marginal para cambios grandes de log**

Dado el modelo de regresión $\log y = \beta_0 + \beta_1 x + u$ estamos interesados en el efecto marginal de x

$$\frac{\Delta \mathbb{E}(y|x)}{\mathbb{E}(y|x)} \times 100 \approx [(\exp(\beta_1) - 1) \times 100] \Delta x.$$

Tenemos un estimador consistente $\hat{\beta}_1$ que satisface $\sqrt{N}(\hat{\beta}_1 - \beta_1) \xrightarrow{d} \text{Normal}(0, V_{11})$.
Proponga un estimador consistente de $(\exp(\beta_1) - 1) \times 100$ y encuentre su distribución asintótica.

- **Efecto marginal para cambios grandes de log**

Dado el modelo de regresión $\log y = \beta_0 + \beta_1 x + u$ estamos interesados en el efecto marginal de x

$$\frac{\Delta \mathbb{E}(y|x)}{\mathbb{E}(y|x)} \times 100 \approx [(\exp(\beta_1) - 1) \times 100] \Delta x.$$

Tenemos un estimador consistente $\hat{\beta}_1$ que satisface $\sqrt{N}(\hat{\beta}_1 - \beta_1) \xrightarrow{d} \text{Normal}(0, V_{11})$.
Proponga un estimador consistente de $(\exp(\beta_1) - 1) \times 100$ y encuentre su distribución asintótica.

- Respuesta: por el método delta con $g(\beta_1) = (\exp(\beta_1) - 1) \times 100$ y $G = g'(\beta_1) = 100 \exp(\beta_1)$,

$$\sqrt{N} \left[(\exp(\hat{\beta}_1) - 1) \times 100 - (\exp(\beta_1) - 1) \times 100 \right] \xrightarrow{d} \text{Normal}(0, 10000 \exp(2\beta_1) V_{11}).$$

Estimador consistente: $(\exp(\hat{\beta}_1) - 1) \times 100$ (teorema de la función continua, $\exp(\cdot)$ es continua).

- Dado el vector aleatorio (x_1, x_2) con

$$\mathbb{E} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}$$

y

$$\text{Var} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{pmatrix}$$

¿Cuál es la distribución asintótica de $z_N = \log(\bar{x}_1) + \log(\bar{x}_2)$

Ejemplos

- Dado el vector aleatorio (x_1, x_2) con

$$\mathbb{E} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}$$

y

$$\text{Var} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{pmatrix}$$

¿Cuál es la distribución asintótica de $z_N = \log(\bar{x}_1) + \log(\bar{x}_2)$

- Respuesta

$$\begin{aligned} & \sqrt{N}((\log(\bar{x}_1) + \log(\bar{x}_2)) - (\log \mu_1 + \log \mu_2)) \\ & \xrightarrow{d} \text{Normal}(0, \frac{\sigma_1^2}{\mu_1^2} + \frac{\sigma_2^2}{\mu_2^2} + 2 \frac{\sigma_{12}}{\mu_1 \mu_2}) \end{aligned}$$

Ejemplos: solución

- Aplicamos el método delta a $g(x_1, x_2) = \log(x_1) + \log(x_2)$, con gradiente

$$G = \left. \frac{\partial g}{\partial (x_1, x_2)'} \right|_{(\mu_1, \mu_2)} = \left(\frac{1}{\mu_1}, \frac{1}{\mu_2} \right)'.$$

La varianza asintótica es

$$\begin{aligned} G' \Sigma G &= \begin{pmatrix} \frac{1}{\mu_1} & \frac{1}{\mu_2} \end{pmatrix} \begin{pmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{pmatrix} \begin{pmatrix} 1/\mu_1 \\ 1/\mu_2 \end{pmatrix} \\ &= \frac{\sigma_1^2}{\mu_1^2} + \frac{\sigma_2^2}{\mu_2^2} + 2 \frac{\sigma_{12}}{\mu_1 \mu_2}. \end{aligned}$$

Por el método delta, $\sqrt{N}(g(\bar{x}_1, \bar{x}_2) - g(\mu_1, \mu_2)) \xrightarrow{d} \text{Normal}(0, G' \Sigma G)$, que es el resultado de la Respuesta.