

Análisis Econométrico

Modelo Lineal de Regresión: Estimación por MCO

Ramiro de Elejalde

Facultad de Economía y Finanzas
Universidad Alberto Hurtado

Outline

Motivación: Efecto del tamaño de clase en el rendimiento académico (California)

Modelo de regresión lineal: Supuestos

Identificación

Estimación por Mínimos Cuadrados Ordinarios (OLS)

Propiedades

Homoscedasticidad

Estimación de la matriz de varianzas-covarianzas

Bondad de ajuste: R^2

Sesgo de variable omitida

Interpretación de efectos marginales

Referencias: Cap. 7 de Hansen, cap. 4.1, 4.2 (excepto 4.2.4) y 4.3.1 de Wooldridge, cap. 6 y cap. 8 (formas funcionales) de Stock y Watson, y cap. 3.1.3 y 3.2.2 de Angrist y Pischke.

Motivación: Tamaño de clase y rendimiento académico

Efecto del tamaño de clase en el rendimiento académico (California)


- **Pregunta de política:** ¿Cuál es el efecto de reducir el tamaño de clase en el rendimiento escolar?
- **Datos:** Todos los distritos escolares de escuelas K-6 y K-8 de California ($N = 420$)
- **Variables:**
 - Notas de examen de 5to grado (Stanford-9 achievement test, matemática y lectura), media del distrito (**testscr**)
 - Ratio estudiantes por profesor: número de estudiantes en el distrito dividido por el número de profesores tiempo completo (**str**).
 - Porcentaje de estudiantes cuya lengua madre no es inglés en el distrito (**el_pct**).

Tabla 1: Resumen de la distribución de los ratios de estudiantes por profesor, del porcentaje de estudiantes que aprenden inglés y de las notas en test estandarizados para 5to grado para 420 distritos escolares en California en 1998

Variable	Media	Desv. est.	P10	P25	P50	P75	P90
Estudiantes/profesor	19.6	1.9	17.3	18.6	19.7	20.9	21.9
% aprendices de inglés	15.8	18.3	0.0	1.9	8.8	23.0	43.9
Nota en test	654.2	19.1	630.4	640.0	654.4	666.7	679.1

Correlación muestral entre *str* y *el_pct*: 0.19.

Figura 1: Scatter plot de notas versus ratio estudiantes/profesor



$$testscr_i = \beta_0 + \beta_1 str_i + u_i,$$

donde u_i contiene todos los factores que influyen sobre el rendimiento escolar además del tamaño de clase.

- **Efecto causal:** β_1 mide el efecto causal de aumentar el tamaño de clase en rendimiento académico.

Podemos usar β_1 para responder: ¿Cuál es el efecto de cambiar un estudiante de una clase de 22 estudiantes a una clase de 17 estudiantes?

$$testscr_i = \beta_0 + \beta_1 str_i + u_i,$$

donde u_i contiene todos los factores que influyen sobre el rendimiento escolar además del tamaño de clase.

- **Efecto causal:** β_1 mide el efecto causal de aumentar el tamaño de clase en rendimiento académico.
- Para poder estimar β_1 necesitamos imponer supuestos sobre u_i .

Formalmente: $\mathbb{E}(u_i | str_i) = 0$.

$$testscr_i = \beta_0 + \beta_1 str_i + u_i,$$

- **Efecto causal:** Necesitamos $\mathbb{E}(u_i|str_i) = 0$.
- Intuitivamente: No debe haber diferencias sistemáticas en factores que puedan afectar el rendimiento académico en alumnos que asisten a escuelas con distintos tamaño de clase.
 1. Buscar **factores que puedan afectar el rendimiento académico** (además del tamaño de clase).
 2. Intuir si estos **factores difieren según el tamaño de clase**.

$$testscr_i = \beta_0 + \beta_1 str_i + u_i,$$

- **Efecto causal:** Necesitamos $\mathbb{E}(u_i|str_i) = 0$.
- Expresa la idea que es imposible observar simultáneamente un mismo estudiante en un clase de 17 alumnos y en una clase de 22 alumnos. Sin embargo, podemos comparar los resultados de estudiantes en clases de 17 alumnos y en clases de 22 alumnos. Establece, bajo qué condiciones, esta comparación permite medir el efecto causal buscado.

$$testscr_i = \beta_0 + \beta_1 str_i + u_i$$

donde u_i contiene todos los factores que influyen sobre el rendimiento escolar además del tamaño de clase.

- ¿En qué situaciones el supuesto $\mathbb{E}(u_i|str_i) = 0$ puede ser válido?
- **Asignación aleatoria** por tamaño de clase. ¿Por qué?

Ejemplo: El proyecto STAR (Student-Teacher Achievement Ratio) en Tennessee, USA.

Efecto causal

- Si no hay asignación aleatoria por tamaño de clase debemos buscar una estrategia alternativa para identificar el efecto causal
- Comparamos alumnos con variables **observables** similares (ingreso, educación de los padres, motivación, etc.) pero en clases de distinto tamaño: **asignación aleatoria condicional en observables**.

$$testscr_i = \beta_0 + \beta_1 str_i + \gamma' x_i + v_i,$$

donde x_i incluye ingreso, educación de los padres, motivación, etc.

- Ejemplo: Efecto de veterano de guerra en salarios.

$$testscr_i = \beta_0 + \beta_1 str_i + u_i$$

donde $\mathbb{E}(u_i|str_i) = 0$

- **Esperanza condicional:**

$$\mathbb{E}(testscr_i|str_i) = \beta_0 + \beta_1 str_i$$

Importante: El supuesto $\mathbb{E}(u_i|str_i) = 0$ nos permite dar una interpretación causal a la esperanza condicional.

$$testscr_i = \beta_0 + \beta_1 str_i + u_i$$

donde $\mathbb{E}(u_i | str_i) = 0$

- **Modelo de regresión lineal:**

$$testscr_i = \beta_0 + \beta_1 str_i + u_i,$$

donde $\beta_1 = \frac{\text{Cov}(str_i, testscr_i)}{\text{Var}(str_i)}$, $\beta_0 = \mathbb{E}(testscr_i) - \beta_1 \mathbb{E}(str_i)$.

Importante: Incluso si creemos que la esperanza condicional no es lineal $y_i = m(x_i) + u_i$, el modelo de regresión nos da la mejor aproximación lineal.

Estimación por Mínimos Cuadrados Ordinarios

$$testscr_i = \beta_0 + \beta_1 str_i + u_i,$$

donde $\mathbb{E}(u_i | str_i) = 0$.

- **Estimación por MCO**

Utilizamos el principio de analogía, es decir reemplazar momentos poblacionales por momentos muestrales.


$\beta_1 = \frac{\text{Cov}(str_i, testscr_i)}{\text{Var}(str_i)}$ se estima con

$$\hat{\beta}_1 = \frac{\widehat{\text{Cov}}(str_i, testscr_i)}{\widehat{\text{Var}}(str_i)},$$

y $\beta_0 = \mathbb{E}(testscr_i) - \beta_1 \mathbb{E}(str_i)$ se estima con $\hat{\beta}_0 = \overline{testscr} - \hat{\beta}_1 \overline{str}$.

- **Consistencia y distribución asintótica normal.**

Estimación MCO: Tamaño de clase y rendimiento académico



Estimación MCO: Tamaño de clase y rendimiento académico

Regresión de *testscr* sobre *str*, con errores estándar robustos entre paréntesis.

	(1)
Constante	698.933 (10.364)
Estudiantes/profesor	-2.280 (0.519)
N	420
R^2	0.051

Estimación MCO: Tamaño de clase y rendimiento académico

Regresión de *testscr* sobre *str* y *el_pct*, con errores estándar robustos entre paréntesis.

	(2)
Constante	686.032 (8.728)
Estudiantes/profesor	-1.101 (0.433)
% aprendices de inglés	-0.650 (0.031)
N	420
R^2	0.426

- En esta unidad discutimos estimación puntual, errores estándar (se) robustos y R^2 .
- En la siguiente unidad contraste de hipótesis (t, F) e intervalos de confianza.

Modelo de regresión lineal: Supuestos

$$\begin{aligned}y_i &= \beta_0 + \beta_1 x_{1i} + \dots + \beta_K x_{Ki} + u_i \\ &= x_i' \beta + u_i,\end{aligned}$$

donde y_i es una variable aleatoria (escalar), x_i es un vector aleatorio de $K \times 1$ (para no tener que trabajar con $K + 1$) y u_i es una variable aleatoria (escalar).

$$y_i = x_i' \beta + u_i$$

- **Supuestos:**

OLS1 Muestra aleatoria de tamaño $N \implies \{y_i, x_i\}_{i=1}^N$ i.i.d.

OLS2 No correlación entre las variables explicativas y el inobservado: $\mathbb{E}(x_i u_i) = 0$.

OLS3 No colinealidad perfecta entre las variables explicativas: $\mathbb{E}(x_i x_i')$ es invertible o $\text{rango}(\mathbb{E}(x_i x_i')) = K$.

OLS4 Condiciones de regularidad (“No fat tails”): $\mathbb{E}(\|x_i\|^4) < \infty$ y $\mathbb{E}(y_i^4) < \infty$.

Identificación

- Escribir los parámetros como una función de momentos poblacionales: ¿Qué momentos poblacionales permiten **identificar** los parámetros de interés?

- Escribir los parámetros como una función de momentos poblacionales: ¿Qué momentos poblacionales permiten **identificar** los parámetros de interés?

$$\mathbb{E}(x_i u_i) = 0 \quad \text{usando OLS2,}$$

$$\iff \mathbb{E}[x_i(y_i - x_i' \beta)] = 0,$$

$$\iff \mathbb{E}(x_i y_i) - \mathbb{E}(x_i x_i') \beta = 0,$$

$$\iff \beta = \mathbb{E}(x_i x_i')^{-1} \mathbb{E}(x_i y_i) \quad \text{usando OLS3.}$$

- OLS2 y OLS3 son los supuestos que identifican β .

Estimación por Mínimos Cuadrados Ordinarios (OLS)

- **Principio de analogía:** reemplazar momentos poblacionales por momentos muestrales.

Mínimos Cuadrados Ordinarios (OLS)

- **Principio de analogía:** reemplazar momentos poblacionales por momentos muestrales.

Estamos interesados en:

$$\beta = \mathbb{E}(x_i x_i')^{-1} \mathbb{E}(x_i y_i).$$

Usando el principio de analogía, lo estimamos con

$$\hat{\beta} = \left(\frac{1}{N} \sum_{i=1}^N x_i x_i' \right)^{-1} \frac{1}{N} \sum_{i=1}^N x_i y_i.$$

- Método de momentos:

Mínimos Cuadrados Ordinarios (OLS)

- **Método de momentos:**

El modelo poblacional cumple

$$\mathbb{E}[x_i(y_i - x_i'\beta)] = 0.$$

El estimador satisface una condición similar en la muestra

$$\frac{1}{N} \sum_{i=1}^N x_i(y_i - x_i'\hat{\beta}) = 0.$$

- Note que

$$\text{Cov}(x_i, u_i) = \text{Cov}(x_i, y_i - x_i'\beta) = 0,$$

$$\widehat{\text{Cov}}(x_i, \hat{u}_i) = \widehat{\text{Cov}}(x_i, y_i - x_i'\hat{\beta}) = 0.$$

Mínimos Cuadrados Ordinarios (OLS)

$$\hat{\beta} = \left(\frac{1}{N} \sum_{i=1}^N x_i x_i' \right)^{-1} \frac{1}{N} \sum_{i=1}^N x_i y_i.$$

- En forma matricial

$$\hat{\beta} = (X'X)^{-1}(X'y),$$

donde X es una matriz de $N \times K$ e y es un vector de $N \times 1$ dados por

$$X = \begin{pmatrix} x_1' \\ \vdots \\ x_N' \end{pmatrix} \quad \text{e} \quad y = \begin{pmatrix} y_1 \\ \vdots \\ y_N \end{pmatrix}$$

$$y_i = \beta_0 + \beta_1 x_{1i} + u_i,$$

donde

$$\beta_1 = \frac{\text{Cov}(x_{1i}, y_i)}{\text{Var}(x_{1i})},$$

$$\beta_0 = \mathbb{E}(y_i) - \beta_1 \mathbb{E}(x_{1i}).$$

$$y_i = \beta_0 + \beta_1 x_{1i} + u_i,$$

donde

$$\beta_1 = \frac{\text{Cov}(x_{1i}, y_i)}{\text{Var}(x_{1i})},$$

$$\beta_0 = \mathbb{E}(y_i) - \beta_1 \mathbb{E}(x_{1i}).$$

El estimador OLS es,

$$\hat{\beta}_1 = \frac{\frac{1}{N} \sum_{i=1}^N x_{1i}(y_i - \bar{y})}{\frac{1}{N} \sum_{i=1}^N x_{1i}(x_{1i} - \bar{x}_1)} = \frac{\frac{1}{N} \sum_{i=1}^N y_i(x_{1i} - \bar{x}_1)}{\frac{1}{N} \sum_{i=1}^N x_{1i}(x_{1i} - \bar{x}_1)} = \frac{\widehat{\text{Cov}}(x_{1i}, y_i)}{\widehat{\text{Var}}(x_{1i})},$$
$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}_1.$$

Dado el modelo de regresión múltiple

$$y_i = \beta_0 + \beta_1 x_{1i} + \dots + \beta_k x_{ki} + \dots + \beta_K x_{Ki} + u_i.$$

Podemos estimar β_1 a partir de:

$$\hat{\beta}_1 = \frac{\widehat{\text{Cov}}(\tilde{x}_{1i}, y_i)}{\widehat{\text{Var}}(\tilde{x}_{1i})},$$

donde

$$x_{1i} = \sum_{j \neq 1} \hat{\gamma}_j x_{ji} + \tilde{x}_{1i} = \hat{x}_{1i} + \tilde{x}_{1i}.$$

- Demostración:

$$\frac{\widehat{\text{Cov}}(\tilde{x}_{1i}, y_i)}{\widehat{\text{Var}}(\tilde{x}_{1i})} = \frac{\widehat{\text{Cov}}(\tilde{x}_{1i}, \hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \dots + \hat{\beta}_K x_{Ki} + \hat{u}_i)}{\widehat{\text{Var}}(\tilde{x}_{1i})}.$$

- (1) $\widehat{\text{Cov}}(\tilde{x}_{1i}, x_{ji}) = 0$ para todo $j \neq 1$, por construcción. En particular $\widehat{\text{Cov}}(\tilde{x}_{1i}, \hat{x}_{1i}) = 0$, porque $\hat{x}_{1i}$ es una combinación lineal de esos x_{ji} ,
- (2) $\widehat{\text{Cov}}(\tilde{x}_{1i}, \hat{u}_i) = 0$ porque $\hat{u}_i$ no está correlacionado con x_i 's y $\tilde{x}_{1i}$ es una función lineal de x_i 's.

Entonces,

$$\frac{\widehat{\text{Cov}}(\tilde{x}_{1i}, y_i)}{\widehat{\text{Var}}(\tilde{x}_{1i})} = \hat{\beta}_1 \frac{\widehat{\text{Cov}}(\tilde{x}_{1i}, x_{1i})}{\widehat{\text{Var}}(\tilde{x}_{1i})} = \hat{\beta}_1 \frac{\widehat{\text{Cov}}(\tilde{x}_{1i}, \hat{x}_{1i} + \tilde{x}_{1i})}{\widehat{\text{Var}}(\tilde{x}_{1i})} = \hat{\beta}_1 \frac{\widehat{\text{Cov}}(\tilde{x}_{1i}, \tilde{x}_{1i})}{\widehat{\text{Var}}(\tilde{x}_{1i})} = \hat{\beta}_1.$$

Mínimos cuadrados: problema de minimización

- Los coeficientes β de la regresión poblacional se pueden definir como la solución del problema de mínimos cuadrados en la población:

$$\beta = \arg \min_b \mathbb{E}[(y_i - x_i' b)^2].$$

- Los estimadores por OLS $\hat{\beta}$ de β se pueden definir como la solución del problema de mínimos cuadrados en la muestra:

$$\hat{\beta} = \arg \min_b \frac{1}{N} \sum_{i=1}^N (y_i - x_i' b)^2.$$

Utilizando las condiciones de primer orden

$$\frac{1}{N} \sum_{i=1}^N x_i (y_i - x_i' \hat{\beta}) = 0 \implies \hat{\beta} = \left(\frac{1}{N} \sum_{i=1}^N x_i x_i' \right)^{-1} \frac{1}{N} \sum_{i=1}^N x_i y_i.$$

Propiedades

Propiedades: Consistencia $\text{plim } \hat{\beta} = \beta$

- Paso intermedio

$$\hat{\beta} = \left(\frac{1}{N} \sum_{i=1}^N x_i x_i' \right)^{-1} \left(\frac{1}{N} \sum_{i=1}^N x_i y_i \right) = \beta + \left(\frac{1}{N} \sum_{i=1}^N x_i x_i' \right)^{-1} \left(\frac{1}{N} \sum_{i=1}^N x_i u_i \right)$$

- Demostración

$$\text{plim } \hat{\beta} = \text{plim } \beta + \left(\text{plim } \frac{1}{N} \sum_{i=1}^N x_i x_i' \right)^{-1} \text{plim } \left(\frac{1}{N} \sum_{i=1}^N x_i u_i \right) = \beta,$$

usando LGN y TFC (la inversa existe y es continua en $\mathbb{E}(x_i x_i')$ por OLS3) en

$$\text{plim } \left(\frac{1}{N} \sum_{i=1}^N x_i x_i' \right) = \mathbb{E}(x_i x_i'),$$

$$\text{plim } \frac{1}{N} \sum_{i=1}^N x_i u_i = \mathbb{E}(x_i u_i) = 0.$$

Repaso: Matriz de varianzas-covarianzas

- Dada una variable aleatoria y su varianza es

$$\text{Var}(y) = \mathbb{E}[(y - \mathbb{E} y)^2] = \mathbb{E}(y^2) - (\mathbb{E} y)^2.$$

- Dado un vector de variables aleatorias $\mathbf{y}$ su matriz de varianzas-covarianzas es

$$\text{Var}(\mathbf{y}) = \mathbb{E}[(\mathbf{y} - \mathbb{E} \mathbf{y})(\mathbf{y} - \mathbb{E} \mathbf{y})'] = \mathbb{E}(\mathbf{y}\mathbf{y}') - (\mathbb{E} \mathbf{y})(\mathbb{E} \mathbf{y})'.$$

- Ejemplo: $\mathbf{y} = (y_1 \ y_2)'$.

- Demostración

$$\sqrt{N}(\hat{\beta} - \beta) = \left(\frac{1}{N} \sum_{i=1}^N x_i x_i' \right)^{-1} \sqrt{N} \frac{1}{N} \sum_{i=1}^N x_i u_i.$$

Usando LGN+TFC y TCL en,

$$\text{plim} \left(\frac{1}{N} \sum_{i=1}^N x_i x_i' \right)^{-1} = \mathbb{E}(x_i x_i')^{-1},$$

$$\sqrt{N} \frac{1}{N} \sum_{i=1}^N x_i u_i \xrightarrow{d} \text{Normal}(0, \mathbb{E}(u_i^2 x_i x_i')).$$

Usando el teorema de Slutsky

$$\sqrt{N}(\hat{\beta} - \beta) \xrightarrow{d} \text{Normal}(0, \mathbb{E}(x_i x_i')^{-1} \mathbb{E}(u_i^2 x_i x_i') \mathbb{E}(x_i x_i')^{-1}).$$

$$\sqrt{N}(\hat{\beta} - \beta) \xrightarrow{d} \text{Normal}(0, \mathbb{E}(x_i x_i')^{-1} \mathbb{E}(u_i^2 x_i x_i') \mathbb{E}(x_i x_i')^{-1}),$$

donde $\mathbb{E}(u_i^2 x_i x_i') < \infty$ bajo el supuesto $\mathbb{E}(\|x_i\|^4) < \infty$ y $\mathbb{E}(y_i^4) < \infty$.

- Decimos

$\hat{\beta} \overset{a}{\sim} \text{Normal}(\beta, \text{AVar}(\hat{\beta}))$, donde

$$\text{AVar}(\hat{\beta}) = \frac{1}{N} \mathbb{E}(x_i x_i')^{-1} \mathbb{E}(u_i^2 x_i x_i') \mathbb{E}(x_i x_i')^{-1}.$$

Ejemplo: Modelo de regresión simple

$$y_i = \beta_0 + \beta_1 x_{1i} + u_i,$$

donde $\mathbb{E}(u_i) = \mathbb{E}(x_{1i} u_i) = 0$

El estimador OLS es,

$$\hat{\beta}_1 = \frac{\frac{1}{N} \sum_{i=1}^N y_i (x_{1i} - \bar{x}_1)}{\frac{1}{N} \sum_{i=1}^N x_{1i} (x_{1i} - \bar{x}_1)} = \frac{\widehat{\text{Cov}}(x_{1i}, y_i)}{\widehat{\text{Var}}(x_{1i})}.$$

Ejemplo: Modelo de regresión simple

En el modelo $y_i = \beta_0 + \beta_1 x_{1i} + u_i$, donde $\mathbb{E}(u_i) = \mathbb{E}(x_{1i} u_i) = 0$,

- La distribución asintótica es

$$\sqrt{N}(\hat{\beta}_1 - \beta_1) \xrightarrow{d} \text{Normal}\left(0, \frac{\mathbb{E}[u^2(x_1 - \mathbb{E}(x_1))^2]}{\text{Var}(x_1)^2}\right),$$

- Decimos

$\hat{\beta}_1 \overset{a}{\sim} \text{Normal}(\beta_1, \text{AVar}(\hat{\beta}_1))$, donde

$$\text{AVar}(\hat{\beta}_1) = \frac{1}{N} \frac{\mathbb{E}[u^2(x_1 - \mathbb{E}(x_1))^2]}{\text{Var}(x_1)^2}.$$

Homoscedasticidad

Homoscedasticidad: $\mathbb{E}(u_i^2|x_i) = \mathbb{E}(u_i^2) = \sigma^2$

- Entonces

$$\mathbb{E}(u_i^2 x_i x_i') = \mathbb{E}[\mathbb{E}(u_i^2|x_i) x_i x_i'] = \sigma^2 \mathbb{E}(x_i x_i'),$$

Por lo tanto

$$\begin{aligned} \text{AVar}(\hat{\beta}) &= \frac{1}{N} \mathbb{E}(x_i x_i')^{-1} \mathbb{E}(u_i^2 x_i x_i') \mathbb{E}(x_i x_i')^{-1}, \\ &= \frac{1}{N} \mathbb{E}(x_i x_i')^{-1} \sigma^2 \mathbb{E}(x_i x_i') \mathbb{E}(x_i x_i')^{-1}, \\ &= \frac{\sigma^2}{N} \mathbb{E}(x_i x_i')^{-1}. \end{aligned}$$

- En el modelo de regresión simple $y_i = \beta_0 + \beta_1 x_{1i} + u_i$:

$$\text{AVar}(\hat{\beta}_1) = \frac{\mathbb{E}(u_i^2)}{N} \frac{1}{\text{Var}(x_{1i})}.$$

Interpretación

- En el modelo de regresión múltiple

$$y_i = \beta_0 + \beta_1 x_{1i} + \dots + \beta_k x_{ki} + \dots + \beta_K x_{Ki} + v_i.$$

Usando la regresión particionada,

$$\text{AVar}(\hat{\beta}_1) = \frac{\mathbb{E}(v_i^2)}{N} \frac{1}{\text{Var}(x_{1i}^\perp)},$$

donde $x_{1i}^\perp = x_{1i} - \mathbb{L}(x_{1i} | x_{2i}, \dots, x_{Ki})$ es el residuo de la proyección lineal *poblacional* de x_{1i} sobre los demás regresores (incluida la constante). Es la versión poblacional de $\tilde{x}_{1i}$, el residuo de la regresión *muestral*.

- En el modelo de regresión simple $y_i = \beta_0 + \beta_1 x_{1i} + u_i$:

$$\text{AVar}(\hat{\beta}_1) = \frac{\mathbb{E}(u_i^2)}{N} \frac{1}{\text{Var}(x_{1i})}.$$

- En el modelo de regresión múltiple

$$y_i = \beta_0 + \beta_1 x_{1i} + \dots + \beta_k x_{ki} + \dots + \beta_K x_{Ki} + v_i.$$

$$\text{AVar}(\hat{\beta}_1) = \frac{\mathbb{E}(v_i^2)}{N} \frac{1}{\text{Var}(x_{1i}^\perp)}.$$

- Comparar

Homoscedasticidad

Si la esperanza condicional no es lineal, entonces, en general, el modelo de regresión es heteroscedástico. (Incluso si $\text{Var}(y_i|x_i)$ es constante.)

Si la esperanza condicional no es lineal, entonces, en general, el modelo de regresión es heteroscedástico. (Incluso si $\text{Var}(y_i|x_i)$ es constante.)

- **Demostración:**

$$\begin{aligned}\mathbb{E}(u_i^2|x_i) &= \mathbb{E}((y_i - x_i'\beta)^2|x_i), \\ &= \mathbb{E}\{[(y_i - \mathbb{E}(y_i|x_i)) + (\mathbb{E}(y_i|x_i) - x_i'\beta)]^2|x_i\}, \\ &= \mathbb{E}[(y_i - \mathbb{E}(y_i|x_i))^2|x_i] + \mathbb{E}[(\mathbb{E}(y_i|x_i) - x_i'\beta)^2|x_i], \\ &= \text{Var}(y_i|x_i) + \mathbb{E}[(\mathbb{E}(y_i|x_i) - x_i'\beta)^2|x_i].\end{aligned}$$

Incluso si $\text{Var}(y_i|x_i)$ es constante, $\mathbb{E}(u_i^2|x_i)$ depende de x_i según el modelo de regresión sea una mejor o peor aproximación a la esperanza condicional para distintos valores de x_i .

- Concluimos que el supuesto de homoscedasticidad es poco probable que se cumpla en la práctica.

Ejemplo: Educación y salarios en US




Figura 2: Regresión y esperanza condicional del log salarios semanales en el nivel educativo. La muestra incluye hombres blancos entre 40 y 49 años de la muestra del 5% del Censo 1980 (IPUMS).

Propiedades en muestras pequeñas: Insesgadez

Si suponemos $\mathbb{E}(u_i|x_i) = 0$ entonces $\mathbb{E}(\hat{\beta}|X) = \beta$ y, por lo tanto, $\mathbb{E}(\hat{\beta}) = \beta$, donde X es la matriz de $N \times K$ con filas x_i' .

Propiedades en muestras pequeñas: Insesgadez

Si suponemos $\mathbb{E}(u_i|x_i) = 0$ entonces $\mathbb{E}(\hat{\beta}|X) = \beta$ y, por lo tanto, $\mathbb{E}(\hat{\beta}) = \beta$, donde X es la matriz de $N \times K$ con filas x_i' .

- Demostración:

$$\mathbb{E}(\hat{\beta}|X) = \beta + \left(\frac{1}{N} \sum_{i=1}^N x_i x_i' \right)^{-1} \frac{1}{N} \sum_{i=1}^N x_i \mathbb{E}(u_i|x_i) = \beta,$$

usando $\mathbb{E}(u_i|X) = \mathbb{E}(u_i|x_i)$ por el supuesto iid y $\mathbb{E}(u_i|x_i) = 0$.

Luego por la LEI

$$\mathbb{E}(\hat{\beta}) = \mathbb{E}[\mathbb{E}(\hat{\beta}|X)] = \mathbb{E}(\beta) = \beta.$$

Teorema de Gauss-Markov

Si $\mathbb{E}(u_i|x_i) = 0$ y $\mathbb{E}(u_i^2|x_i) = \sigma^2$ (homoscedasticidad), entonces $\hat{\beta}$ es el estimador de menor varianza (condicional en X) entre los estimadores insesgados y lineales en y .

Teorema de Gauss-Markov

Si $\mathbb{E}(u_i|x_i) = 0$ y $\mathbb{E}(u_i^2|x_i) = \sigma^2$ (homoscedasticidad), entonces $\hat{\beta}$ es el estimador de menor varianza (condicional en X) entre los estimadores insesgados y lineales en y .

- Demostración (sketch): Sea $\hat{Q} = \frac{1}{N} \sum_{i=1}^N x_i x_i'$. Calculamos la varianza condicional

$$\begin{aligned}\text{Var}(\hat{\beta}|X) &= \mathbb{E}[(\hat{\beta} - \beta)(\hat{\beta} - \beta)'|X], \\ &= \hat{Q}^{-1} \mathbb{E} \left[\left(\frac{1}{N} \sum_{i=1}^N x_i u_i \right) \left(\frac{1}{N} \sum_{i=1}^N x_i' u_i \right) | X \right] \hat{Q}^{-1}, \\ &= \hat{Q}^{-1} \left(\frac{1}{N^2} \sum_{i=1}^N x_i x_i' \mathbb{E}(u_i^2|x_i) \right) \hat{Q}^{-1} = \frac{\sigma^2}{N} \hat{Q}^{-1},\end{aligned}$$

usando que $\mathbb{E}(u_i u_j | X) = 0$ para $i \neq j$ (muestra i.i.d. y $\mathbb{E}(u_i|x_i) = 0$).

Teorema de Gauss-Markov

Si $\hat{\beta}$ minimiza la varianza condicional $\text{Var}(b|X)$ entonces minimiza la varianza no condicional $\text{Var}(b)$, donde b son estimadores insesgados de β .

Teorema de Gauss-Markov

Si $\hat{\beta}$ minimiza la varianza condicional $\text{Var}(b|X)$ entonces minimiza la varianza no condicional $\text{Var}(b)$, donde b son estimadores insesgados de β .

- Demostración: Sabemos que

$$\text{Var}(\hat{\beta}|X) \leq \text{Var}(b|X)$$

donde b es un estimador insesgado de β . Utilizando la descomposición de varianza

$$\text{Var}(b) = \mathbb{E}[\text{Var}(b|X)] + \text{Var}[\mathbb{E}(b|X)].$$

Pero hemos demostrado anteriormente que:

$$\text{Var}[\mathbb{E}(\hat{\beta}|X)] = \text{Var}(\beta) = 0.$$

Entonces $\text{Var}(\hat{\beta}|X) \leq \text{Var}(b|X) \implies \text{Var}(\hat{\beta}) \leq \text{Var}(b)$ donde b es un estimador insesgado de β .

Estimación de la matriz de varianzas-covarianzas

- Supongamos homoscedasticidad $\mathbb{E}(u_i^2|x_i) = \sigma^2$.

Estamos interesados en un estimador consistente de

$$A\text{Var}(\sqrt{N}(\hat{\beta} - \beta)) = \sigma^2 \mathbb{E}(x_i x_i')^{-1}.$$

- Supongamos homoscedasticidad $\mathbb{E}(u_i^2|x_i) = \sigma^2$.

Estamos interesados en un estimador consistente de

$$A\text{Var}(\sqrt{N}(\hat{\beta} - \beta)) = \sigma^2 \mathbb{E}(x_i x_i')^{-1}.$$

Puede ser una buena idea usar:

$$\widehat{A\text{Var}}(\sqrt{N}(\hat{\beta} - \beta)) = \left(\frac{1}{N} \sum_{i=1}^N \hat{u}_i^2 \right) \left(\frac{1}{N} \sum_{i=1}^N x_i x_i' \right)^{-1} = \hat{\sigma}^2 \left(\frac{1}{N} \sum_{i=1}^N x_i x_i' \right)^{-1},$$

donde $\hat{u}_i = y_i - x_i' \hat{\beta}$.

- **Demostración:** Anteriormente demostramos que

$$\text{plim} \left(\frac{1}{N} \sum_{i=1}^N x_i x_i' \right)^{-1} = \mathbb{E}(x_i x_i')^{-1}.$$

- Nos queda demostrar que $\text{plim} \hat{\sigma}^2 = \sigma^2$:

- Nos queda demostrar que $\text{plim } \hat{\sigma}^2 = \sigma^2$:

$$\begin{aligned}\frac{1}{N} \sum_{i=1}^N \hat{u}_i^2 &= \frac{1}{N} \sum_{i=1}^N (y_i - \mathbf{x}_i' \hat{\beta})^2, \\&= \frac{1}{N} \sum_{i=1}^N [(y_i - \mathbf{x}_i' \beta) - (\mathbf{x}_i' \hat{\beta} - \mathbf{x}_i' \beta)]^2, \\&= \frac{1}{N} \sum_{i=1}^N [(y_i - \mathbf{x}_i' \beta)^2 + (\mathbf{x}_i' \hat{\beta} - \mathbf{x}_i' \beta)^2 - 2(\mathbf{x}_i' \hat{\beta} - \mathbf{x}_i' \beta)(y_i - \mathbf{x}_i' \beta)], \\&= \frac{1}{N} \sum_{i=1}^N [u_i^2 + (\hat{\beta} - \beta)' \mathbf{x}_i \mathbf{x}_i' (\hat{\beta} - \beta) - 2(\hat{\beta} - \beta)' \mathbf{x}_i u_i], \\&= \frac{1}{N} \sum_{i=1}^N u_i^2 + (\hat{\beta} - \beta)' \left(\frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i' \right) (\hat{\beta} - \beta) - 2(\hat{\beta} - \beta)' \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i u_i.\end{aligned}$$

Homoscedasticidad

- Nos queda demostrar $\text{plim } \frac{1}{N} \sum_{i=1}^N \hat{u}_i^2 = \sigma^2$:

$$\frac{1}{N} \sum_{i=1}^N \hat{u}_i^2 = \frac{1}{N} \sum_{i=1}^N u_i^2 + (\hat{\beta} - \beta)' \left(\frac{1}{N} \sum_{i=1}^N x_i x_i' \right) (\hat{\beta} - \beta) - 2(\hat{\beta} - \beta)' \frac{1}{N} \sum_{i=1}^N x_i u_i.$$

Utilizando LGN y TFC

$$\text{plim } \frac{1}{N} \sum_{i=1}^N u_i^2 = \mathbb{E}(u_i^2) = \sigma^2,$$

$$\text{plim}(\hat{\beta} - \beta)' \text{plim} \left(\frac{1}{N} \sum_{i=1}^N x_i x_i' \right) \text{plim}(\hat{\beta} - \beta) = 0 \times \mathbb{E}(x_i x_i') \times 0 = 0,$$

$$\text{plim}(\hat{\beta} - \beta)' \text{plim} \left(\frac{1}{N} \sum_{i=1}^N x_i u_i \right) = 0 \times \mathbb{E}(x_i u_i) = 0.$$

Concluimos que $\text{plim } \hat{\sigma}^2 = \text{plim } \frac{1}{N} \sum_{i=1}^N \hat{u}_i^2 = \mathbb{E}(u_i^2) = \sigma^2$.

- Los programas estadísticos como Stata utilizan como estimador de σ^2 a

$$\tilde{\sigma}^2 = \frac{1}{N-K} \sum_{i=1}^N \hat{u}_i^2 = \frac{N}{N-K} \frac{1}{N} \sum_{i=1}^N \hat{u}_i^2 \xrightarrow{p} \sigma^2.$$

La justificación es que $\tilde{\sigma}^2$ es un estimador insesgado de σ^2 cuando asumimos $\mathbb{E}(u_i|x_i) = 0$ y $\mathbb{E}(u_i^2|x_i) = \sigma^2$ (homoscedasticidad).

- Desde el punto de vista asintótico este ajuste de grados de libertad es irrelevante.

- Resumen: **Bajo homoscedasticidad**

Decimos $\hat{\beta} \stackrel{a}{\sim} \text{Normal}(\beta, \text{AVar}(\hat{\beta}))$, donde

$$\text{AVar}(\hat{\beta}) = \frac{1}{N} \mathbb{E}(u_i^2) \mathbb{E}(x_i x_i')^{-1} = \frac{\sigma^2}{N} \mathbb{E}(x_i x_i')^{-1}.$$

Un estimador consistente de $\text{AVar}(\hat{\beta})$ viene dado por

$$\widehat{\text{AVar}}(\hat{\beta}) = \frac{1}{N} \left(\frac{1}{N} \sum_{i=1}^N \hat{u}_i^2 \right) \left(\frac{1}{N} \sum_{i=1}^N x_i x_i' \right)^{-1} = \frac{\hat{\sigma}^2}{N} \left(\frac{1}{N} \sum_{i=1}^N x_i x_i' \right)^{-1}.$$

Por lo tanto $\text{s.e.}(\hat{\beta}_k) = \sqrt{\widehat{\text{AVar}}(\hat{\beta})_{kk}}$

- **Bajo heteroscedasticidad.**

Estamos interesados en un estimador consistente de

$$\text{AVar}(\sqrt{N}(\hat{\beta} - \beta)) = \mathbb{E}(x_i x_i')^{-1} \mathbb{E}(u_i^2 x_i x_i') \mathbb{E}(x_i x_i')^{-1}.$$

Puede ser buena idea usar:

$$\widehat{\text{AVar}}(\sqrt{N}(\hat{\beta} - \beta)) = \left(\frac{1}{N} \sum_{i=1}^N x_i x_i' \right)^{-1} \left(\frac{1}{N} \sum_{i=1}^N \hat{u}_i^2 x_i x_i' \right) \left(\frac{1}{N} \sum_{i=1}^N x_i x_i' \right)^{-1},$$

donde $\hat{u}_i = y_i - x_i' \hat{\beta}$.

- Usando argumentos similares al caso homoscedástico pero más engorrosos se puede demostrar que

$$\text{plim} \frac{1}{N} \sum_{i=1}^N \hat{u}_i^2 x_i x_i' = \mathbb{E}(u_i^2 x_i x_i').$$

- Resumen: **Bajo heteroscedasticidad**

Decimos $\hat{\beta} \stackrel{a}{\sim} \text{Normal}(\beta, \text{AVar}(\hat{\beta}))$, donde

$$\text{AVar}(\hat{\beta}) = \frac{1}{N} \mathbb{E}(x_i x_i')^{-1} \mathbb{E}(u_i^2 x_i x_i') \mathbb{E}(x_i x_i')^{-1}.$$

Un estimador consistente de $\text{AVar}(\hat{\beta})$ viene dado por

$$\widehat{\text{AVar}}(\hat{\beta}) = \frac{1}{N} \left(\frac{1}{N} \sum_{i=1}^N x_i x_i' \right)^{-1} \left(\frac{1}{N} \sum_{i=1}^N \hat{u}_i^2 x_i x_i' \right) \left(\frac{1}{N} \sum_{i=1}^N x_i x_i' \right)^{-1}.$$

Por lo tanto $\text{s.e.}(\hat{\beta}_k) = \sqrt{\widehat{\text{AVar}}(\hat{\beta})_{kk}}$

Nota: los programas (*robust* en Stata, *HC1* en R) multiplican $\widehat{\text{AVar}}(\hat{\beta})$ por $N/(N - K)$. Asintóticamente es irrelevante; las tablas de estas láminas usan *HC1*.

- Bajo homoscedasticidad

$$\widehat{\text{AVar}}(\hat{\beta}) = \frac{\hat{\sigma}^2}{N} \left(\frac{1}{N} \sum_{i=1}^N x_i x_i' \right)^{-1}.$$

Definimos X e y , donde X es una matriz de $N \times K$ e y es un vector de $N \times 1$, dados por

$$X = \begin{pmatrix} x_1' \\ \vdots \\ x_N' \end{pmatrix} \quad \text{e} \quad y = \begin{pmatrix} y_1 \\ \vdots \\ y_N \end{pmatrix}$$

- Bajo homoscedasticidad

$$\widehat{\text{AVar}}(\hat{\beta}) = \frac{\hat{\sigma}^2}{N} \left(\frac{1}{N} \sum_{i=1}^N x_i x_i' \right)^{-1}.$$

En forma matricial

$$\widehat{\text{AVar}}(\hat{\beta}) = \hat{\sigma}^2 (X'X)^{-1},$$

donde X es una matriz de $N \times K$, y es un vector de $N \times 1$ y

$$\hat{\sigma}^2 = \frac{1}{N} \hat{u}' \hat{u},$$

donde $\hat{u} = y - X\hat{\beta}$ es un vector de $N \times 1$.

- Bajo heteroscedasticidad

$$\widehat{\text{AVar}}(\hat{\beta}) = \frac{1}{N} \left(\frac{1}{N} \sum_{i=1}^N x_i x_i' \right)^{-1} \left(\frac{1}{N} \sum_{i=1}^N \hat{u}_i^2 x_i x_i' \right) \left(\frac{1}{N} \sum_{i=1}^N x_i x_i' \right)^{-1}.$$

En forma matricial

$$\widehat{\text{AVar}}(\hat{\beta}) = N (X'X)^{-1} S (X'X)^{-1},$$

donde X es una matriz de $N \times K$, y es un vector de $N \times 1$ y

$$S = \frac{1}{N} X' \text{diag}(\hat{u}_1^2, \dots, \hat{u}_N^2) X,$$

donde $\text{diag}(\cdot)$ es una matriz diagonal de $N \times N$ con $\hat{u}_1^2, \dots, \hat{u}_N^2$ en la diagonal principal.

Bondad de ajuste: R^2

Bondad de ajuste: R^2

- R^2 poblacional

$$R^2 = 1 - \frac{\mathbb{E}(u_i^2)}{\text{Var}(y_i)}.$$

- $\hat{R}^2$ muestral

$$\hat{R}^2 = 1 - \frac{\frac{1}{N} \sum_{i=1}^N \hat{u}_i^2}{\widehat{\text{Var}}(y_i)}.$$

Interpretación

Sesgo de variable omitida

Efecto del tamaño de clase en el rendimiento académico (California)

- Pregunta de política: ¿Cuál es el efecto de reducir el tamaño de clase en el rendimiento escolar?

Estimación MCO: Tamaño de clase y rendimiento académico

Regresión de *testscr* sobre *str*, con errores estándar robustos entre paréntesis.

	(1)
Constante	698.933 (10.364)
Estudiantes/profesor	-2.280 (0.519)
N	420
R^2	0.051

Efecto del tamaño de clase en el rendimiento académico (California)

- Pregunta de política: ¿Cuál es el efecto de reducir el tamaño de clase en el rendimiento escolar?
- Respuesta: Si reducimos el tamaño de clase en un alumno por profesor, el rendimiento académico aumentaría, en media, en 2.28 puntos.
- ¿Es nuestra respuesta convincente? Depende del supuesto $\text{Cov}(u_i, str_i) = 0$.
- Dado que no tenemos asignación aleatoria, en este caso el supuesto no parece válido.
- **Sesgo de variable omitida:** Hay variables no observadas que afectan al tamaño de clase y el rendimiento escolar

Sesgo de variable omitida

- Solución: Incluir la variable relevante omitida como variable explicativa.

Sesgo de variable omitida

- Solución: Incluir la variable relevante omitida como variable explicativa.
- Intuición: Controlar por variables observables para hacer estudiantes en distintos tamaños de clase comparables. Buscamos generar **asignación aleatoria condicional en observables**.

- Variables que nos gustaría observar
 1. Características de las escuelas: ratio estudiantes por profesor, calidad de los profesores, computadoras (recursos materiales) por estudiante, medidas del diseño del plan de estudios, ...
 2. Características de los estudiantes: manejo del inglés, actividades extra-curriculares, ambiente de aprendizaje en la casa, nivel educativo de los padres,...
- Variables que observamos:
 1. ratio estudiantes por profesor (*str*),
 2. porcentaje de personas cuya lengua madre no es inglés en el distrito (*el_pct*),
 3. porcentaje elegible para un subsidio para el almuerzo (*meal_pct*),
 4. porcentaje que recibe un subsidio público (*calw_pct*).

Estimación MCO: Tamaño de clase y rendimiento académico

Variable dependiente: *testscr*. Errores estándar robustos entre paréntesis.

	(1)	(2)	(3)	(4)	(5)
Constante	698.93*** (10.36)	686.03*** (8.73)	700.15*** (5.57)	698.00*** (6.92)	700.39*** (5.54)
Estudiantes/profesor	-2.28*** (0.52)	-1.10* (0.43)	-1.00*** (0.27)	-1.31*** (0.34)	-1.01*** (0.27)
% aprendices de inglés		-0.65*** (0.03)	-0.12*** (0.03)	-0.49*** (0.03)	-0.13*** (0.04)
% con subsidio de almuerzo			-0.55*** (0.02)		-0.53*** (0.04)
% con asistencia pública				-0.79*** (0.07)	-0.05 (0.06)
N	420	420	420	420	420
R ²	0.05	0.43	0.77	0.63	0.77

* $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$

- Signo del sesgo de variable omitida.

Sesgo de variable omitida: Tamaño de clase y rendimiento académico

- Signo del sesgo de variable omitida al omitir *el_pct*.

Sesgo de variable omitida: Tamaño de clase y rendimiento académico

- Signo del sesgo de variable omitida al omitir *el_pct*.
- $\beta_{el_pct} < 0$ (modelo 2) y la correlación muestral entre *str* y *el_pct* es positiva (0.19).

Sesgo de variable omitida: Tamaño de clase y rendimiento académico

- Signo del sesgo de variable omitida al omitir *el_pct*.
- $\beta_{el_pct} < 0$ (modelo 2) y la correlación muestral entre *str* y *el_pct* es positiva (0.19).
- Entonces el sesgo asintótico del coeficiente de *str* es negativo: omitir *el_pct* sobrestima el efecto negativo del tamaño de clase (-2.28 sin controles versus -1.10 con *el_pct*).

Sesgo de variable omitida

- El siguiente modelo de regresión mide un efecto causal

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + u_i, \quad \text{donde } \text{Cov}(x_{1i}, u_i) = \text{Cov}(x_{2i}, u_i) = 0.$$

Sin embargo, no podemos observar x_{2i} y estimamos el modelo

$$y_i = \gamma_0 + \gamma_1 x_{1i} + v_i.$$

$$\text{plim } \hat{\gamma}_1 = \frac{\text{plim } \widehat{\text{Cov}}(x_{1i}, y_i)}{\text{plim } \widehat{\text{Var}}(x_{1i})} = \frac{\text{Cov}(x_{1i}, y_i)}{\text{Var}(x_{1i})} = \beta_1 + \beta_2 \frac{\text{Cov}(x_{1i}, x_{2i})}{\text{Var}(x_{1i})},$$

$$\text{Sesgo Asintótico}(\hat{\gamma}_1) = \text{plim } \hat{\gamma}_1 - \beta_1 = \beta_2 \frac{\text{Cov}(x_{1i}, x_{2i})}{\text{Var}(x_{1i})}.$$

El signo del sesgo asintótico depende de β_2 y $\text{Cov}(x_{1i}, x_{2i})$

Ejemplo: Efecto de educación en salarios

- $lwage_i = \log(\text{salarios})$, $educ_i = \text{años de educación}$, y $abil_i = \text{habilidad innata}$.
- Tenemos los modelos

$$lwage_i = \beta_0 + \beta_{educ}educ_i + \beta_{abil}abil_i + u_i.$$

$$lwage_i = \gamma_0 + \gamma_{educ}educ_i + v_i.$$

- Entonces

$$\begin{aligned}\text{Sesgo Asintótico}(\hat{\gamma}_{educ}) &= \text{plim } \hat{\gamma}_{educ} - \beta_{educ}, \\ &= \beta_{abil} \frac{\text{Cov}(educ_i, abil_i)}{\text{Var}(educ_i)}.\end{aligned}$$

$$\beta_{abil} > 0, \text{Cov}(educ_i, abil_i) > 0 \implies \text{Sesgo Asintótico}(\hat{\gamma}_{educ}) > 0$$

Interpretación de efectos marginales

Efectos marginales

- Dado una forma funcional para $\mathbb{E}(y|x_1, \dots, x_K)$, el **efecto marginal** de cambios en x_j manteniendo constantes x_k para todo $k \neq j$ se puede aproximar por

$$\Delta \mathbb{E}(y|x) \approx \frac{\partial \mathbb{E}(y|x)}{\partial x_j} \Delta x_j,$$

para x_j continua, y

$$\Delta \mathbb{E}(y|x) = \mathbb{E}(y|x_j=1, x_k \text{ fijas } \forall k \neq j) - \mathbb{E}(y|x_j=0, x_k \text{ fijas } \forall k \neq j),$$

para x_j binaria.

- Lineal

$$\mathbb{E}(y|x_1, x_2) = \beta_0 + \beta_1 x_1 + \beta_2 x_2,$$

$$\frac{\partial \mathbb{E}(y|x)}{\partial x_j} = \beta_j \Rightarrow \Delta \mathbb{E}(y|x) = \beta_j \Delta x_j.$$

- Cuadrático

$$\mathbb{E}(y|x_1, x_2) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_2^2,$$

$$\frac{\partial \mathbb{E}(y|x)}{\partial x_2} = \beta_2 + 2\beta_3 x_2 \Rightarrow \Delta \mathbb{E}(y|x) \approx (\beta_2 + 2\beta_3 x_2) \Delta x_2.$$

- Interacciones

$$\mathbb{E}(y|x_1, x_2) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_2 x_1,$$

$$\frac{\partial \mathbb{E}(y|x)}{\partial x_2} = \beta_2 + \beta_3 x_1 \Rightarrow \Delta \mathbb{E}(y|x) \approx (\beta_2 + \beta_3 x_1) \Delta x_2.$$

Efecto del tamaño de clase en el rendimiento educativo

- Modelo

$$\mathbb{E}(\text{testscr} | \text{str}, \text{el_pct}) = \beta_0 + \beta_{\text{str}} \text{str} + \beta_{\text{el_pct}} \text{el_pct},$$

donde *testscr* es la nota en un test estandarizado, *str* es el ratio de estudiantes por profesor y *el_pct* es el porcentaje de estudiantes cuya lengua madre no es inglés (en %).

- Información: $\mathbb{E}(\text{testscr}) = 654$, $\mathbb{E}(\text{str}) = 20$, $\mathbb{E}(\text{el_pct}) = 16$, $\beta_{\text{str}} = -1.10$, $\beta_{\text{el_pct}} = -0.65$.
- Efecto marginal de *str* y *el_pct*

- Modelo

$$\begin{aligned}\mathbb{E}(\textit{wage}|\textit{educ}, \textit{exper}, IQ) = & \beta_0 + \beta_{\textit{educ}} \textit{educ} + \beta_{\textit{exper}} \textit{exper} \\ & + \beta_{\textit{exper}^2} \textit{exper}^2 + \beta_{IQ} IQ + \beta_{\textit{educ}_IQ} \textit{educ} \times IQ,\end{aligned}$$

donde *wage* es salarios mensuales para hombres entre 28 y 38 años, *educ* son años de educación formal, *exper* son años de experiencia laboral y *IQ* es el resultado en test de inteligencia.

- Información: $\mathbb{E}(\textit{wage}) = 958$, $\mathbb{E}(\textit{educ}) = 13$, $\mathbb{E}(\textit{exper}) = 12$, $\mathbb{E}(IQ) = 101$, $sd(IQ) = 15.05$, $\beta_{\textit{educ}} = 22.79$, $\beta_{\textit{exper}} = 18.35$, $\beta_{\textit{exper}^2} = -0.05$, $\beta_{IQ} = 0.69$ y $\beta_{\textit{educ}_IQ} = 0.33$.
- Efecto marginal de *exper* y *educ*

$$\begin{aligned}\mathbb{E}(y|x) &= \beta_0 + \beta_1 \log x_1 + \beta_2 x_2, \\ \frac{\partial \mathbb{E}(y|x)}{\partial x_1} &= \beta_1 \frac{1}{x_1} \\ \Rightarrow \Delta \mathbb{E}(y|x) &\approx \beta_1 \frac{\Delta x_1}{x_1}, \\ &= \frac{\beta_1}{100} \left(\frac{\Delta x_1}{x_1} \times 100 \right).\end{aligned}$$

Nota: Diferencias entre **cambios porcentuales versus cambios en puntos porcentuales**.
En la práctica, $\log x_1$ versus x_1 medido en puntos porcentuales.

Efectos de la contaminación en los precios de las viviendas

- Modelo

$$\mathbb{E}(\textit{price}|\textit{nox}, \textit{rooms}, \textit{stratio}) = \beta_0 + \beta_{\textit{nox}} \log(\textit{nox}) + \beta_{\textit{rooms}} \textit{rooms} \\ + \beta_{\textit{stratio}} \textit{stratio},$$

donde *price* es el precio de la vivienda, *nox* es la cantidad de óxido nitroso en el aire (contaminación), *rooms* es el número de habitaciones y *stratio* es el ratio estudiantes/profesor en la comuna.

- Información: $\mathbb{E}(\textit{price}) = 22,511$, $\mathbb{E}(\textit{nox}) = 5.55$, $\mathbb{E}(\textit{rooms}) = 6.28$, $\mathbb{E}(\textit{stratio}) = 18$, $\beta_{\textit{nox}} = -9,344$, $\beta_{\textit{rooms}} = 7,069$, y $\beta_{\textit{stratio}} = -1,130$.
- Efecto marginal de *nox*.

$$\begin{aligned}\log \mathbb{E}(y|x_1, x_2) &= \beta_0 + \beta_1 x_1 + \beta_2 x_2, \\ \iff \mathbb{E}(y|x_1, x_2) &= \exp(\beta_0 + \beta_1 x_1 + \beta_2 x_2), \\ \frac{\partial \mathbb{E}(y|x)}{\partial x_1} &= \mathbb{E}(y|x) \beta_1, \\ \Rightarrow \Delta \mathbb{E}(y|x) &\approx \mathbb{E}(y|x) \beta_1 \Delta x_1, \\ \Rightarrow \frac{\Delta \mathbb{E}(y|x)}{\mathbb{E}(y|x)} \times 100 &\approx (\beta_1 \times 100) \Delta x_1.\end{aligned}$$

- Modelo

$$\mathbb{E}(\log(wage)|educ, exper) = \beta_0 + \beta_{educ} educ \\ + \beta_{exper} exper + \beta_{exper^2} exper^2,$$

donde *wage* es salarios mensuales, *educ* son años de educación formal, y *exper* son años de experiencia laboral.

- Información: $\beta_{educ} = 0.078$.
- Efecto marginal de *educ*.

$$\mathbb{E}(y|x) = \exp(x'\beta) \Rightarrow \log \mathbb{E}(y|x) = x'\beta.$$

Pero, en general, trabajamos con

$$\mathbb{E}(\log y|x) = x'\beta,$$

utilizando un modelo

$$\log y = x'\beta + u, \quad \text{con } u \perp\!\!\!\perp x,$$

entonces

$$\frac{\partial \mathbb{E}(\log y|x)}{\partial x_j} = \frac{\partial \log(\mathbb{E}(y|x))}{\partial x_j} = \beta_j.$$

Note que necesitamos imponer independencia.

Efectos de la contaminación en los precios de las viviendas

- Modelo

$$\mathbb{E}(\log(\text{price}) | \text{nox}, \text{rooms}, \text{stratio}) = \beta_0 + \beta_{\text{nox}} \log(\text{nox}) \\ + \beta_{\text{rooms}} \text{rooms} + \beta_{\text{stratio}} \text{stratio},$$

donde *price* es el precio de la vivienda, *nox* es la cantidad de óxido nitroso en el aire (contaminación), *rooms* es el número de habitaciones y *stratio* es el ratio estudiante/profesor en la comuna.

- Información: $\mathbb{E}(\text{rooms}) = 6.28$, $\mathbb{E}(\text{stratio}) = 18$, $\beta_{\text{rooms}} = 0.257$, y $\beta_{\text{stratio}} = -0.051$.
- Efecto marginal de *rooms* y *stratio*.

Efectos de la contaminación en los precios de las viviendas

- Modelo

$$\mathbb{E}(\log(\textit{price})|\textit{nox}, \textit{rooms}, \textit{stratio}) = \beta_0 + \beta_{\textit{nox}} \log(\textit{nox}) \\ + \beta_{\textit{rooms}} \textit{rooms} + \beta_{\textit{stratio}} \textit{stratio},$$

donde *price* es el precio de la vivienda, *nox* es la cantidad de óxido nitroso en el aire (contaminación), *rooms* es el número de habitaciones y *stratio* es el ratio estudiante/profesor en la comuna.

- Información: $\beta_{\textit{nox}} = -0.645$.
- Efecto marginal de *nox*.

$$\begin{aligned}\log \mathbb{E}(y|x_1, x_2) &= \beta_0 + \beta_1 \log(x_1) + \beta_2 x_2, \\ \iff \mathbb{E}(y|x_1, x_2) &= \exp(\beta_0 + \beta_1 \log(x_1) + \beta_2 x_2), \\ \frac{\partial \mathbb{E}(y|x)}{\partial x_1} &= \frac{\mathbb{E}(y|x)}{x_1} \beta_1, \\ \Rightarrow \Delta \mathbb{E}(y|x) &\approx \frac{\mathbb{E}(y|x)}{x_1} \beta_1 \Delta x_1, \\ \Rightarrow \frac{\Delta \mathbb{E}(y|x)}{\mathbb{E}(y|x)} \times 100 &\approx \beta_1 \left(\frac{\Delta x_1}{x_1} \times 100 \right).\end{aligned}$$

Resumen: Modelos con logaritmos

- Resumen

1. Nivel-log

$$y = \beta_0 + \beta_1 \log x_1 + \beta_2 x_2 + u,$$

Un cambio de x_1 en un 1% está asociado, aproximadamente, con un cambio en la media de y de $0.01 \beta_1$ unidades.

2. Log-nivel

$$\log y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u,$$

Un cambio de x_1 en 1 unidad está asociado, aproximadamente, con un cambio en la media de y de $100\beta_1\%$.

3. Log-log

$$\log y = \beta_0 + \beta_1 \log(x_1) + \beta_2 x_2 + u,$$

Un cambio de x_1 en un 1% está asociado, aproximadamente, con un cambio en la media de y de $\beta_1\%$ (elasticidad).

- Una variable dummy d_j (por ejemplo, *female*)

$$\mathbb{E}(y|d_1) = \beta_0 + \beta_1 d_1,$$

$$\Rightarrow \mathbb{E}(y|d_1=1) = \beta_0 + \beta_1$$

$$\Rightarrow \mathbb{E}(y|d_1=0) = \beta_0$$

$$\Rightarrow \mathbb{E}(y|d_1=1) - \mathbb{E}(y|d_1=0) = \beta_1.$$

Efecto de ser veterano de guerra en ingresos

- Modelo

$$\mathbb{E}(\text{earnings}|dvet) = \beta_0 + \beta_{dvet} dvet,$$

donde *earnings* es el ingreso en 1988-1991 de los hombres que solicitaron entrar a las fuerzas armadas entre 1979 y 1982 y *dvet* es una dummy de veterano de guerra.

- Información: $\mathbb{E}(\text{earnings}) = 12,431$, y $\beta_{dvet} = 1,101$.
- Efecto marginal de *dvet*.

- Modelo

$$\mathbb{E}(ahe|bachelor) = \beta_0 + \beta_{bachelor} bachelor,$$

donde *ahe* son los ingresos por hora en 2008 de personas entre 25 y 34 años que poseen estudios secundarios o universitarios y *bachelor* es una dummy de graduado universitario.

- Información: $\mathbb{E}(ahe) = 18.98$, $\beta_0 = 15.33$ y $\beta_{bachelor} = 7.58$.
- Efecto marginal de *bachelor*.

- Interacciones entre variables dummies (por ejemplo, *female*, y *married*)

$$\mathbb{E}(y|d_1, d_2) = \beta_0 + \beta_1 d_1 + \beta_2 d_2 + \beta_3 d_1 \times d_2,$$

$$\Rightarrow \mathbb{E}(y|d_1=1, d_2=1) = \beta_0 + \beta_1 + \beta_2 + \beta_3$$

$$\Rightarrow \mathbb{E}(y|d_1=1, d_2=0) = \beta_0 + \beta_1$$

$$\Rightarrow \mathbb{E}(y|d_1=0, d_2=1) = \beta_0 + \beta_2$$

$$\Rightarrow \mathbb{E}(y|d_1=0, d_2=0) = \beta_0$$

- Dos modelos equivalentes

$$y = \beta_0 + \beta_1 \textit{female} + \beta_2 \textit{married} + \beta_3 \textit{female} \times \textit{married} + u, \quad (1)$$

$$y = \delta_0 + \delta_1 \textit{female_married} + \delta_2 \textit{female_nonmarried} + \delta_3 \textit{male_married} + u. \quad (2)$$

Efecto de ser veterano de guerra en ingresos

- Modelo

$$\mathbb{E}(\text{earnings} | d_{\text{vet}}, d_{\text{nwhite}}) = \beta_0 + \beta_{d_{\text{vet}}} d_{\text{vet}} + \beta_{d_{\text{nwhite}}} d_{\text{nwhite}} \\ + \beta_{d_{\text{vet}} \cdot d_{\text{nwhite}}} d_{\text{vet}} \times d_{\text{nwhite}},$$

donde *earnings* es el ingreso en 1988-1991 de los hombres que solicitaron entrar a las fuerzas armadas entre 1979 y 1982, *dvet* es una dummy de veterano de guerra y *dnwhite* es una dummy que indica que la persona NO es de raza blanca.

- Información: $\mathbb{E}(\text{earnings}) = 12,431$, $\beta_{d_{\text{vet}}} = 787$, $\beta_{d_{\text{nwhite}}} = -2,272$ y $\beta_{d_{\text{vet}} \cdot d_{\text{nwhite}}} = 629$.
- Efecto marginal de *dvet*.

- Modelo

$$\mathbb{E}(ahe|bachelor) = \beta_0 + \beta_{bachelor} bachelor + \beta_{d2008} d2008 \\ + \beta_{bachelor_d2008} bachelor \times d2008,$$

donde *ahe* es el ingreso por hora (en dólares de 2008) en 1992 y 2008 de personas entre 25 y 34 años que poseen estudios secundarios o universitarios y *bachelor* es una dummy de graduado universitario.

- Información: $\mathbb{E}(ahe) = 18.41$, $\beta_0 = 15.31$, $\beta_{bachelor} = 6.47$, $\beta_{d2008} = 0.02$ y $\beta_{bachelor_d2008} = 1.11$.
- Efecto marginal de *bachelor* en 1992 y 2008.

- Interacciones entre variables dummies y continuas

$$\mathbb{E}(y|d_1, x) = \beta_0 + \beta_1 d_1 + \beta_2 x + \beta_3 d_1 \times x,$$

$$\Rightarrow \mathbb{E}(y|d_1=1, x) = \beta_0 + \beta_1 + (\beta_2 + \beta_3)x$$

$$\Rightarrow \mathbb{E}(y|d_1=0, x) = \beta_0 + \beta_2 x$$

$$\Rightarrow \Delta \mathbb{E}(y|x) \approx (\beta_2 + \beta_3 d_1)\Delta x.$$

- Modelo

$$\mathbb{E}(\log(wage)|educ, female) = \beta_0 + \beta_{educ} educ + \beta_{female} female \\ + \beta_{educ_female} educ \times female,$$

donde *wage* es el ingreso por hora de trabajadores de 29 a 30 años en US en 2004 (CPS Marzo 2005), *educ* es años de educación y *female* es una dummy de mujer.

- Información: $\beta_{educ} = 0.0912$, $\beta_{female} = -0.3265$ y $\beta_{educ_female} = 0.0102$.
- Efecto marginal de *educ*.

Cambios grandes con logaritmo

- Cuando los efectos marginales son grandes, $\frac{\partial \log y}{\partial x}$ puede que no sea una buena aproximación a $\frac{\Delta y}{\Delta x}$. Podemos calcular el cambio exacto.

Cambios grandes con logaritmo

- Cuando los efectos marginales son grandes, $\frac{\partial \log y}{\partial x}$ puede que no sea una buena aproximación a $\frac{\frac{\Delta y}{y}}{\Delta x}$. Podemos calcular el cambio exacto.
- Dado el modelo $\log y = \beta_0 + \beta_1 x + u$, donde $u \perp x$. Podemos escribir

$$\mathbb{E}(y|x) = \exp(\beta_0 + \beta_1 x) \mathbb{E}(\exp(u)),$$

de donde

$$\begin{aligned} \frac{\mathbb{E}(y|x = \bar{x} + 1) - \mathbb{E}(y|x = \bar{x})}{\mathbb{E}(y|x = \bar{x})} \times 100 &= \left(\frac{\exp(\beta_0 + \beta_1(\bar{x} + 1))}{\exp(\beta_0 + \beta_1(\bar{x}))} - 1 \right) \times 100 \\ &= (\exp(\beta_1) - 1) \times 100. \end{aligned}$$

Efectos de la contaminación en los precios de las viviendas

- Modelo

$$\mathbb{E}(\log(\text{price}) | \text{nox}, \text{rooms}, \text{stratio}) = \beta_0 + \beta_{\text{nox}} \log(\text{nox}) \\ + \beta_{\text{rooms}} \text{rooms} + \beta_{\text{stratio}} \text{stratio},$$

donde *price* es el precio de la vivienda, *nox* es la cantidad de óxido nitroso en el aire (contaminación), *rooms* es el número de habitaciones y *stratio* es el ratio estudiante/profesor en la comuna.

- Información: $\mathbb{E}(\text{rooms}) = 6.28$ y $\mathbb{E}(\text{stratio}) = 18$, $\beta_{\text{rooms}} = 0.257$
- Efecto marginal de *rooms*
 $(\exp(\beta_{\text{rooms}}) - 1) \times 100 = 29.3\%$.