Análisis Econométrico
Modelo Lineal de Regresión: Inferencia por MCO

Ramiro de Elejalde

Facultad de Economía y Finanzas
Universidad Alberto Hurtado

Outline

Contraste de una restricción lineal sobre un parámetro

Intervalo de confianza

Una restricción lineal sobre múltiples parámetros

Múltiples restricciones lineales

Restricciones no lineales

Referencias: Cap. 7 y 9 de Hansen, cap. 3.5.2 y 4.2.3 de Wooldridge, y cap. 7 de Stock y Watson.

Repaso: estimación por MCO

- **Consistencia**: $\text{plim}\,\hat{\beta} = \beta$.
- **Distribución asintótica normal**: $\sqrt{N}(\hat{\beta} - \beta) \xrightarrow{d} \text{Normal}(0, V)$, donde $V = \mathbb{E}(x_i x_i')^{-1}\,\mathbb{E}(u_i^2 x_i x_i')\,\mathbb{E}(x_i x_i')^{-1}$.
- **Estimación consistente de la matriz de varianzas y covarianzas**: $\hat{V} \xrightarrow{p} V$.
- Usando estos resultados,

$$\hat{\beta} \overset{a}{\sim} \text{Normal}\left(\beta, \frac{V}{N}\right), \text{ y}$$

$$s.e.(\hat{\beta}_j) = \frac{\hat{v}_{jj}^{1/2}}{N^{1/2}} \quad \text{donde } v_{jj} \text{ es el elemento } jj \text{ de } V.$$

Estimación MCO: Tamaño de clase y rendimiento académico

Modelo (clase 4): $testscr_i = \beta_0 + \beta_1\, str_i + \beta_2\, el_pct_i + u_i$.

Variable dependiente: *testscr*. Regresores: *str* y *el_pct*. Errores estándar robustos.

Variable	Coef.	Error est.	t	p-valor	IC 95% inf.	IC 95% sup.
str	-1.101	0.433	-2.544	0.011	-1.952	-0.250
el_pct	-0.650	0.031	-20.939	< 0.001	-0.711	-0.589
Constante	686.032	8.728	78.599	< 0.001	668.875	703.189

$N = 420$, $R^2 = 0.426$. Errores estándar robustos (HC1).

Contraste de hipótesis e intervalos de confianza

- En esta unidad vamos a estudiar cómo incorporar la influencia de la aleatoriedad muestral en el análisis de los resultados.

  $\Longrightarrow$ **Contraste de hipótesis**

  $\Longrightarrow$ **Intervalos de confianza**

Contraste de una restricción lineal sobre un parámetro

Contraste de una restricción lineal sobre un parámetro

Hipótesis nula

$$H_0 : \beta_j = \beta_{j,0}.$$

Hipótesis alternativa

$$H_1 : \beta_j \neq \beta_{j,0}.$$

Contraste de una restricción lineal sobre un parámetro

- **Regla de decisión**: Un estadístico T_N, un valor crítico c_α y una regla de decisión:

  1. No rechazar H_0 si $T_N \leq c_\alpha$,
  2. Rechazar H_0 si $T_N > c_\alpha$.

Contraste de una restricción lineal sobre un parámetro

- **Regla de decisión**: Un estadístico T_N, un valor crítico c_α y una regla de decisión:

  1. No rechazar H_0 si $T_N \leq c_\alpha$,
  2. Rechazar H_0 si $T_N > c_\alpha$.

- **Test estadístico**: Estadístico t en valor absoluto

$$|t_N| = \left| \frac{\hat{\beta}_j - \beta_{j,0}}{s.e.(\hat{\beta}_j)} \right|$$

Error tipo I y tamaño del test

	Decisión en el contraste de hipótesis	
	No rechazar H_0	Rechazar H_0
H_0 es verdadera	Decisión correcta	Error tipo I
H_1 es verdadera	Error tipo II	Decisión correcta

- El **tamaño del test** es la probabilidad del error tipo I. El **tamaño asintótico del test** α es dicha probabilidad en el límite:

$$\lim_{N\to\infty} \Pr(\text{Rechazar } H_0|H_0) = \lim_{N\to\infty} \Pr(T_N > c_\alpha|H_0) = \Pr(T > c_\alpha) = \alpha$$

$$\text{donde } T_N \xrightarrow{d} T \text{ bajo } H_0.$$

Error tipo I y tamaño del test

	Decisión en el contraste de hipótesis	
	No rechazar H_0	Rechazar H_0
H_0 es verdadera	Decisión correcta	Error tipo I
H_1 es verdadera	Error tipo II	Decisión correcta

- Clave: Buscar T_N cuya distribución asintótica bajo H_0 sea conocida.
- Si la distribución asintótica de T_N no depende de parámetros desconocidos, el estadístico es **asintóticamente pivotal**.
- Fijamos α y obtenemos c_α de la distribución asintótica de T_N.

Una restricción lineal sobre un parámetro

- **Test estadístico**: Estadístico t en valor absoluto

$$|t_N| = \left| \frac{\hat{\beta}_j - \beta_{j,0}}{s.e.(\hat{\beta}_j)} \right| \xrightarrow{d}_{H_0} |Z|,$$

donde $Z \sim \text{Normal}(0, 1)$ y $\Pr(|Z| \leq u) = 2\Phi(u) - 1$

Una restricción lineal sobre un parámetro

- **Test estadístico**: Estadístico t en valor absoluto

$$|t_N| = \left| \frac{\hat{\beta}_j - \beta_{j,0}}{s.e.(\hat{\beta}_j)} \right| \xrightarrow{d}_{H_0} |Z|,$$

donde $Z \sim \text{Normal}(0,1)$ y $\Pr(|Z| \leq u) = 2\Phi(u) - 1$

Demostración:

$$t_N = \frac{\hat{\beta}_j - \beta_{j,0}}{s.e.(\hat{\beta}_j)} = \sqrt{N}\frac{\hat{\beta}_j - \beta_{j,0}}{\hat{v}_{jj}^{1/2}}$$

$$= \sqrt{N}\frac{\hat{\beta}_j - \beta_{j,0}}{v_{jj}^{1/2}} \frac{v_{jj}^{1/2}}{\hat{v}_{jj}^{1/2}} \xrightarrow{d}_{H_0} Z \sim \text{Normal}(0,1),$$

usando la distribución asintótica normal, $\hat{v}_{jj} \xrightarrow{p} v_{jj}$ y el teorema de Slutsky.

Una restricción lineal sobre un parámetro

- **Test estadístico**: Estadístico t en valor absoluto

$$|t_N| = \left| \frac{\hat{\beta}_j - \beta_{j,0}}{s.e.(\hat{\beta}_j)} \right| \xrightarrow{d}_{H_0} |Z|$$

donde $Z \sim \text{Normal}(0,1)$ y $\Pr(|Z| \leq u) = 2\Phi(u) - 1$.

Demostración: Como $t_N \xrightarrow{d}_{H_0} Z \sim \text{Normal}(0,1)$, por el teorema de la función continua $|t_N| \xrightarrow{d}_{H_0} |Z|$. La probabilidad acumulada de $|Z|$ es

$$\begin{aligned} \Pr(|Z| \leq u) &= \Pr(-u \leq Z \leq u) = \Phi(u) - \Phi(-u) \\ &= \Phi(u) - (1 - \Phi(u)) = 2\Phi(u) - 1. \end{aligned}$$

Una restricción lineal sobre un parámetro

- **Test estadístico**: Estadístico t en valor absoluto

$$|t_N| = \left| \frac{\hat{\beta}_j - \beta_{j,0}}{s.e.(\hat{\beta}_j)} \right| \xrightarrow{d}_{H_0} |Z|,$$

  donde $Z \sim \text{Normal}(0,1)$ y $\Pr(|Z| \leq u) = 2\Phi(u) - 1$.

- **Valor crítico** $c_\alpha = z_{1-\alpha/2}$ donde α es el tamaño del test y $\Phi(z_{1-\alpha/2}) = 1 - \alpha/2$.

Una restricción lineal sobre un parámetro

- **Test estadístico**: Estadístico t en valor absoluto

$$|t_N| = \left| \frac{\hat{\beta}_j - \beta_{j,0}}{s.e.(\hat{\beta}_j)} \right| \xrightarrow{d}_{H_0} |Z|,$$

donde $Z \sim \text{Normal}(0,1)$ y $\Pr(|Z| \leq u) = 2\Phi(u) - 1$.

- **Valor crítico** $c_\alpha = z_{1-\alpha/2}$ donde α es el tamaño del test y $\Phi(z_{1-\alpha/2}) = 1 - \alpha/2$.

Demostración:

$$\lim_{N\to\infty} \Pr(\text{Rechazar } H_0|H_0) = \lim_{N\to\infty} \Pr(|t_N| > c_\alpha|H_0) = \Pr(|Z| > c_\alpha) = \alpha.$$

Pero

$$\Pr(|Z| > c_\alpha) = 1 - \Pr(|Z| \leq c_\alpha) = 1 - (2\Phi(c_\alpha) - 1) = 2(1 - \Phi(c_\alpha)) = \alpha$$
$$\iff \Phi(c_\alpha) = 1 - \alpha/2 \iff c_\alpha = z_{1-\alpha/2}.$$

Una restricción lineal sobre un parámetro

- **Test estadístico**: Estadístico t en valor absoluto

$$|t_N| = \left| \frac{\hat{\beta}_j - \beta_{j,0}}{s.e.(\hat{\beta}_j)} \right| \xrightarrow{d}_{H_0} |Z|,$$

  donde $Z \sim \text{Normal}(0,1)$ y $\Pr(|Z| \leq u) = 2\Phi(u) - 1$.

- **Valor crítico** $c_\alpha = z_{1-\alpha/2}$ donde α es el tamaño del test.
  Si $\alpha = 0.05$, entonces $c_\alpha = z_{0.975} = 1.96$.

- **Regla de decisión**: Si $|t_N| > z_{1-\alpha/2}$, rechazamos H_0.
  Cuando rechazamos la hipótesis nula $H_0 : \beta_j = 0$, solemos decir que β_j es **estadísticamente significativo**.

Ejemplo: Tamaño de clase y rendimiento académico

- Modelo

$$testscr_i = \beta_0 + \beta_1\, str_i + \beta_2 el_pct_i + u_i,$$

- **Hipótesis nula**: El tamaño de clase no tiene efecto sobre el rendimiento académico.
  Formalmente:

$$H_0 : \beta_1 = 0.$$

- **Hipótesis alternativa**: El tamaño de clase tiene efecto sobre el rendimiento académico.
  Formalmente:

$$H_1 : \beta_1 \neq 0.$$

Tamaño de clase y rendimiento académico

Variable dependiente: *testscr*. Regresores: *str* y *el_pct*. Errores estándar robustos.

Variable	Coef.	Error est.	t	p-valor	IC 95% inf.	IC 95% sup.
str	-1.101	0.433	-2.544	0.011	-1.952	-0.250
el_pct	-0.650	0.031	-20.939	< 0.001	-0.711	-0.589
Constante	686.032	8.728	78.599	< 0.001	668.875	703.189

$N = 420$, $R^2 = 0.426$. Errores estándar robustos (HC1).

- $t_N = -1.101/0.433 = -2.54$ y $|t_N| > 1.96$: rechazamos H_0 al 5%.
- Significatividad estadística vs. relevancia económica: reducir *str* en 2 alumnos por profesor aumenta *testscr* en 2.2 puntos, 0.12 desviaciones estándar de *testscr* (19.1).

En R: test t y p-valor

```
library(haven); library(sandwich); library(lmtest)

ca <- read_dta("caschool.dta")
m <- lm(testscr ~ str + el_pct, data = ca)

# coeficientes, errores estandar robustos, t y p-valor
coeftest(m, vcov = vcovHC(m, type = "HC1"))
```

Para *str*: $t = -2.544$ y p-valor $= 0.011$. `coeftest` usa la t de Student con $N - K$ grados de libertad.

p-valor

El **p-valor** se define como $p_N = \Pr(T > T_N)$ donde $T_N \xrightarrow{d}_{H_0} T$.

- **Intuición**: La regla de decisión es rechazar H_0 si $T_N > c_\alpha$ donde $\Pr(T > c_\alpha) = \alpha$. Una regla de decisión equivalente es calcular el p-valor $\Pr(T > T_N) = p_N$ y rechazar si $p_N < \alpha$.

p-valor

El **p-valor** se define como $p_N = \Pr(T > T_N)$ donde $T_N \xrightarrow{d}_{H_0} T$.

- **Intuición**: La regla de decisión es rechazar H_0 si $T_N > c_\alpha$ donde $\Pr(T > c_\alpha) = \alpha$. Una regla de decisión equivalente es calcular el p-valor $\Pr(T > T_N) = p_N$ y rechazar si $p_N < \alpha$.
- Dado que $\Pr(T > T_N)$ es decreciente en T_N, el p-valor es una transformación monótona de T_N y por lo tanto es un estadístico equivalente.
- **El p-valor es el nivel de significatividad marginal**: el menor valor de α para el cual se rechaza H_0.
- Para $H_0 : \beta_j = \beta_{j,0}$ y $H_1 : \beta_j \neq \beta_{j,0}$ con el estadístico t tenemos:

$$p_N = \Pr(T > T_N) = \Pr(|Z| > |t_N|) = 2(1 - \Phi(|t_N|)).$$

Tamaño de clase y rendimiento académico

Variable dependiente: *testscr*. Regresores: *str* y *el_pct*. Errores estándar robustos.

Variable	Coef.	Error est.	t	p-valor	IC 95% inf.	IC 95% sup.
str	-1.101	0.433	-2.544	0.011	-1.952	-0.250
el_pct	-0.650	0.031	-20.939	< 0.001	-0.711	-0.589
Constante	686.032	8.728	78.599	< 0.001	668.875	703.189

$N = 420$, $R^2 = 0.426$. Errores estándar robustos (HC1).

- p-valor $= 0.011$: rechazamos H_0 al 5%, pero no al 1%.

Error tipo II y poder del test

	Decisión en el contraste de hipótesis	
	No rechazar H_0	Rechazar H_0
H_0 es verdadera	Decisión correcta	Error tipo I
H_1 es verdadera	Error tipo II	Decisión correcta

- El **poder del test** $\pi_N(\beta_j)$ es uno menos la probabilidad del error tipo II:

$$\Pr(\text{Rechazar } H_0 | H_1) = \Pr(T_N > c_\alpha | H_1) = \pi_N(\beta_j).$$

Error tipo II y poder del test

	Decisión en el contraste de hipótesis	
	No rechazar H_0	Rechazar H_0
H_0 es verdadera	Decisión correcta	Error tipo I
H_1 es verdadera	Error tipo II	Decisión correcta

- El **poder del test** $\pi_N(\beta_j)$ es uno menos la probabilidad del error tipo II:

$$\Pr(\text{Rechazar } H_0|H_1) = \Pr(T_N > c_\alpha|H_1) = \pi_N(\beta_j).$$

- En general, el poder del test aumenta a medida que β_j se aleja de $\beta_{j,0}$ y a medida que el tamaño de la muestra aumenta.
- No podemos reducir ambos errores a la vez: fijamos el tamaño del test α y, entre los tests con ese tamaño, preferimos el de mayor poder, que es el más informativo sobre H_0.
- Si el poder es igual al tamaño del test, el test no provee información sobre la hipótesis de interés.

Consistencia

- **Consistencia** frente a la alternativa fija H_1: Si rechazamos con probabilidad uno bajo H_1 cuando $N \to \infty$,

$$\begin{aligned}\lim_{N\to\infty} \pi_N(\beta_j) &= \lim_{N\to\infty} \Pr(\text{Rechazar } H_0|H_1) \\ &= \lim_{N\to\infty} \Pr(T_N > c_\alpha|H_1) \\ &= 1.\end{aligned}$$

Consistencia

- **Test estadístico**: Estadístico t en valor absoluto

$$|t_N| = \left| \frac{\hat{\beta}_j - \beta_{j,0}}{s.e.(\hat{\beta}_j)} \right| \xrightarrow[H_0]{d} |Z|,$$

  donde $Z \sim \text{Normal}(0, 1)$ y $\Pr(|Z| \leq u) = 2\Phi(u) - 1$.

- El contraste con el test estadístico t es **consistente**.

Consistencia

- **Test estadístico**: Estadístico t en valor absoluto

$$|t_N| = \left| \frac{\hat{\beta}_j - \beta_{j,0}}{s.e.(\hat{\beta}_j)} \right| \xrightarrow{d}_{H_0} |Z|,$$

donde $Z \sim \text{Normal}(0,1)$ y $\Pr(|Z| \leq u) = 2\Phi(u) - 1$.

- El contraste con el test estadístico t es **consistente**.

Demostración

$$t_N = \frac{\hat{\beta}_j - \beta_{j,0}}{s.e.(\hat{\beta}_j)} = \frac{\hat{\beta}_j - \beta_j}{s.e.(\hat{\beta}_j)} + \sqrt{N}\frac{\beta_j - \beta_{j,0}}{\hat{v}_{jj}^{1/2}}$$

Bajo H_1, el primer término $\xrightarrow{d} Z \sim \text{Normal}(0,1)$ y el segundo diverge a $+\infty$ si $\beta_j > \beta_{j,0}$ y a $-\infty$ si $\beta_j < \beta_{j,0}$. Entonces $|t_N| \xrightarrow{p} \infty$ y $\lim_{N\to\infty} \Pr(|t_N| > z_{1-\alpha/2}|H_1) = 1$.

Poder asintótico local

- Consistencia es un requisito mínimo para un test, pero no es una buena aproximación al poder del test.
- Una **alternativa local** es una hipótesis alternativa $H_{1,N}$ que converge a H_0 a cierta velocidad. En este caso, $\beta_{j,N} = \beta_{j,0} + N^{-1/2}h$ donde h es un parámetro.
- El **poder asintótico local** de un test es el límite cuando $N \to \infty$ del poder del test bajo la alternativa local:

$$\lim_{N\to\infty} \Pr(\text{Rechazar } H_0 | H_{1,N}) = \lim_{N\to\infty} \Pr(T_N > c_\alpha | H_{1,N}).$$

Poder asintótico local

- **Poder asintótico local del test es decreciente en v_{jj}**

  Dada la alternativa local $H_{1,N} : \beta_{j,N} = \beta_{j,0} + N^{-1/2}h$, el poder asintótico es $\lim_{N\to\infty} \Pr(|t_N| > z_{1-\alpha/2}|H_{1,N}) = \Phi(\delta - c_\alpha) + \Phi(-\delta - c_\alpha)$ donde $\delta = h/v_{jj}^{1/2}$. El poder local es decreciente en v_{jj} (dado h).

- **Poder asintótico local del test es decreciente en v_{jj}**

  Dada la alternativa local $H_{1,N} : \beta_{j,N} = \beta_{j,0} + N^{-1/2}h$, el poder asintótico es $\lim_{N\to\infty} \Pr(|t_N| > z_{1-\alpha/2}|H_{1,N}) = \Phi(\delta - c_\alpha) + \Phi(-\delta - c_\alpha)$ donde $\delta = h/v_{jj}^{1/2}$. El poder local es decreciente en v_{jj} (dado h).

  Demostración

$$t_N = \frac{\hat{\beta}_j - \beta_{j,0}}{s.e.(\hat{\beta}_j)} = \frac{\hat{\beta}_j - \beta_{j,N}}{s.e.(\hat{\beta}_j)} + \sqrt{N}\frac{\beta_{j,N} - \beta_{j,0}}{\hat{v}_{jj}^{1/2}}$$

$$= \frac{\hat{\beta}_j - \beta_{j,N}}{s.e.(\hat{\beta}_j)} + \frac{h}{\hat{v}_{jj}^{1/2}} \xrightarrow{d}_{H_{1,N}} Z + \delta \quad \text{donde } Z \sim \text{Normal}(0,1),$$

  utilizando $\beta_{j,N} = \beta_{j,0} + h\,N^{-1/2}$.

Poder asintótico local

- **Poder asintótico local del test es decreciente en v_{jj}**

  Dada la alternativa local $H_{1,N} : \beta_{j,N} = \beta_{j,0} + N^{-1/2}h$, el poder asintótico es $\lim_{N\to\infty} \Pr(|t_N| > z_{1-\alpha/2}|H_{1,N}) = \Phi(\delta - c_\alpha) + \Phi(-\delta - c_\alpha)$ donde $\delta = h/v_{jj}^{1/2}$. El poder local es creciente en $|\delta|$.

  Demostración: Como $t_N \xrightarrow{d}_{H_{1,N}} Z + \delta$, donde $Z \sim \text{Normal}(0,1)$,

$$\begin{aligned}\lim_{N\to\infty} \Pr(|t_N| > z_{1-\alpha/2}|H_{1,N}) &= \Pr(|Z+\delta| > c_\alpha) = 1 - \Pr(-c_\alpha - \delta < Z < c_\alpha - \delta) \\ &= 1 - [\Phi(c_\alpha - \delta) - \Phi(-c_\alpha - \delta)] \\ &= \Phi(-c_\alpha + \delta) + \Phi(-c_\alpha - \delta).\end{aligned}$$

Poder asintótico local del test t

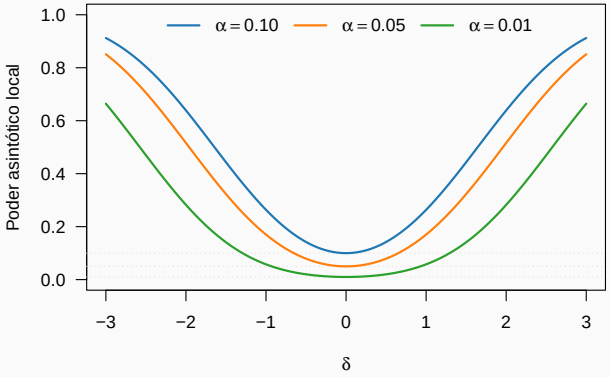


Figura 1: Poder asintótico local del test t de dos colas en función de $\delta = h/v_{jj}^{1/2}$.

Hipótesis alternativa de una cola

- **Hipótesis nula**

$$H_0 : \beta_j = \beta_{j,0}.$$

- **Hipótesis alternativa**

$$H_1 : \beta_j > \beta_{j,0}.$$

- **Test estadístico**: Estadístico t

$$t_N = \frac{\hat{\beta}_j - \beta_{j,0}}{s.e.(\hat{\beta}_j)} \xrightarrow{d}_{H_0} Z \quad \text{donde} \quad Z \sim \text{Normal}(0,1).$$

- **Valor crítico** $c_\alpha = z_{1-\alpha}$:

$$\lim_{N\to\infty} \Pr(\text{Rechazar } H_0 | H_0) = \lim_{N\to\infty} \Pr(t_N > c_\alpha | H_0) = \Pr(Z > c_\alpha) = \alpha \iff c_\alpha = z_{1-\alpha}.$$

  Si $\alpha = 0.05$, entonces $c_\alpha = z_{0.95} = 1.645$.

- **Regla de decisión**: Si $t_N > c_\alpha$, rechazamos H_0.

Hipótesis alternativa de una cola

- **Hipótesis nula**

$$H_0 : \beta_j = \beta_{j,0}.$$

- **Hipótesis alternativa**

$$H_1 : \beta_j < \beta_{j,0}.$$

- **Test estadístico**: Estadístico t

$$t_N = \frac{\hat{\beta}_j - \beta_{j,0}}{s.e.(\hat{\beta}_j)} \xrightarrow{d}_{H_0} Z \quad \text{donde} \quad Z \sim \text{Normal}(0,1).$$

- **Valor crítico** $c_\alpha = z_{1-\alpha}$:

$$\begin{aligned}\lim_{N\to\infty} \Pr(\text{Rechazar } H_0 | H_0) &= \lim_{N\to\infty} \Pr(-t_N > c_\alpha | H_0) \\ &= \lim_{N\to\infty} \Pr(t_N \leq -c_\alpha | H_0) = \alpha \\ &\iff \Pr(Z \leq -c_\alpha) = \alpha \iff c_\alpha = z_{1-\alpha}.\end{aligned}$$

Hipótesis alternativa de una cola

- **Hipótesis nula**

$$H_0 : \beta_j = \beta_{j,0}.$$

- **Hipótesis alternativa**

$$H_1 : \beta_j < \beta_{j,0}.$$

- **Test estadístico**: Estadístico t

$$t_N = \frac{\hat{\beta}_j - \beta_{j,0}}{s.e.(\hat{\beta}_j)} \xrightarrow{d}_{H_0} Z \quad \text{donde} \quad Z \sim \text{Normal}(0, 1).$$

- **Valor crítico** $c_\alpha = z_{1-\alpha}$. Si $\alpha = 0.05$, entonces $c_\alpha = z_{0.95} = 1.645$.
- **Regla de decisión**: Si $t_N < -c_\alpha$ (es decir, $-t_N > c_\alpha$), rechazamos H_0.

p-valor

- Para $H_0 : \beta_j = \beta_{j,0}$ y $H_1 : \beta_j > \beta_{j,0}$, tenemos:

$$p_N = \Pr(T > T_N) = \Pr(Z > t_N) = 1 - \Phi(t_N).$$

- Para $H_0 : \beta_j = \beta_{j,0}$ y $H_1 : \beta_j < \beta_{j,0}$, tenemos:

$$p_N = \Pr(T > T_N) = \Pr(-Z > -t_N) = \Pr(Z < t_N) = \Phi(t_N)$$

Intervalo de confianza

Intervalo de confianza

- $\hat{\beta}_j$ es una estimación puntual de β_j.
- Un concepto más amplio, es un **intervalo de confianza** $\hat{C}_N = [L_N, U_N]$ con el objetivo de que el $100(1-\alpha)\%$ de las veces (**nivel de cobertura o nivel de confianza**) dicho intervalo contenga a β_j: $\lim_{N\to\infty} \Pr(\beta_j \in \hat{C}_N) = 1-\alpha$
- Para un nivel de confianza de $1-\alpha$:

$$\hat{C}_N = [\hat{\beta}_j - c_\alpha \, s.e.(\hat{\beta}_j), \hat{\beta}_j + c_\alpha \, s.e.(\hat{\beta}_j)]$$

Intervalo de confianza

- Para un nivel de confianza de $1-\alpha$:

$$\lim_{N\to\infty} \Pr\left(-c_\alpha < \frac{\hat{\beta}_j - \beta_j}{s.e.(\hat{\beta}_j)} < c_\alpha\right) = \Pr\left(-c_\alpha < Z < c_\alpha\right) = 1-\alpha$$

donde $Z \sim \text{Normal}(0,1)$ y $c_\alpha = z_{1-\alpha/2}$. Entonces,

$$\lim_{N\to\infty} \Pr\left(-c_\alpha < \frac{\hat{\beta}_j - \beta_j}{s.e.(\hat{\beta}_j)} < c_\alpha\right) =$$
$$\lim_{N\to\infty} \Pr\left(\hat{\beta}_j - c_\alpha\, s.e.(\hat{\beta}_j) < \beta_j < \hat{\beta}_j + c_\alpha\, s.e.(\hat{\beta}_j)\right) = 1-\alpha.$$

Por lo tanto $\hat{C}_N = [\hat{\beta}_j - c_\alpha\, s.e.(\hat{\beta}_j), \hat{\beta}_j + c_\alpha\, s.e.(\hat{\beta}_j)]$

Estimación MCO: Tamaño de clase y rendimiento académico

Variable dependiente: *testscr*. Regresores: *str* y *el_pct*. Errores estándar robustos.

Variable	Coef.	Error est.	t	p-valor	IC 95% inf.	IC 95% sup.
str	-1.101	0.433	-2.544	0.011	-1.952	-0.250
el_pct	-0.650	0.031	-20.939	< 0.001	-0.711	-0.589
Constante	686.032	8.728	78.599	< 0.001	668.875	703.189

$N = 420$, $R^2 = 0.426$. Errores estándar robustos (HC1).

- $[-1.101 - 1.96 \times 0.433,\ -1.101 + 1.96 \times 0.433] = [-1.950,\ -0.253]$.
- La tabla reporta $[-1.952,\ -0.250]$: R y Stata utilizan los valores críticos de la t de Student con $N - K$ grados de libertad.
- El intervalo contiene los valores $\beta_{j,0}$ que el test t de dos colas no rechaza al nivel α. Como $0 \notin [-1.950,\ -0.253]$, rechazamos $H_0 : \beta_1 = 0$ al 5%, igual que con el test t.

En R: intervalo de confianza

```
coefci(m, vcov. = vcovHC(m, type = "HC1"), level = 0.95)
```

Para *str*: $[-1.952, -0.250]$, con valores críticos de la t de Student.

Una restricción lineal sobre múltiples parámetros

Una restricción lineal sobre múltiples parámetros

- **Hipótesis nula**

$$H_0 : r'\beta = \theta_0,$$

  donde r es un vector de $K \times 1$ y θ_0 es un escalar.

- **Hipótesis alternativa**

$$H_1 : r'\beta \neq \theta_0.$$

Una restricción lineal sobre múltiples parámetros

- **Hipótesis nula**

$$H_0 : r'\beta = \theta_0,$$

  donde r es un vector de $K \times 1$ y θ_0 es un escalar.

- **Hipótesis alternativa**

$$H_1 : r'\beta \neq \theta_0.$$

- **Regla de decisión**: Un estadístico T_N, un valor crítico c_α y una regla de decisión:

  1. No rechazar H_0 si $T_N \leq c_\alpha$,
  2. Rechazar H_0 si $T_N > c_\alpha$.

Una restricción lineal sobre múltiples parámetros

- **Test estadístico**: Estadístico t en valor absoluto

$$|t_N| = \left| \sqrt{N} \frac{r'\hat{\beta} - \theta_0}{\sqrt{r'\hat{V}r}} \right| \xrightarrow[H_0]{d} |Z| \quad \text{donde} \quad Z \sim \text{Normal}(0, 1).$$

Una restricción lineal sobre múltiples parámetros

- **Test estadístico**: Estadístico t en valor absoluto

$$|t_N| = \left| \sqrt{N} \frac{r'\hat{\beta} - \theta_0}{\sqrt{r'\hat{V}r}} \right| \xrightarrow{d}_{H_0} |Z| \quad \text{donde} \quad Z \sim \text{Normal}(0,1).$$

Demostración: Utilizando la distribución asintótica normal:

$$\sqrt{N}(\hat{\beta} - \beta) \xrightarrow{d} \text{Normal}(0, V).$$

Utilizando el método delta para $g(x) = r'x$,

$$\sqrt{N}(r'\hat{\beta} - r'\beta) \xrightarrow{d} \text{Normal}(0, r'Vr),$$

$$\implies \sqrt{N}(r'\hat{\beta} - \theta_0) \xrightarrow{d}_{H_0} \text{Normal}(0, r'Vr).$$

Utilizando $\hat{V} \xrightarrow{p} V$ y el teorema de Slutsky,

$$t_N = \frac{\sqrt{N}(r'\hat{\beta} - \theta_0)}{\sqrt{r'\hat{V}r}} \xrightarrow{d}_{H_0} Z \sim \text{Normal}(0,1).$$

Una restricción lineal sobre múltiples parámetros

- **Test estadístico**: Estadístico t en valor absoluto

$$|t_N| = \left| \sqrt{N} \frac{r'\hat{\beta} - \theta_0}{\sqrt{r'\hat{V}r}} \right| \xrightarrow{d}_{H_0} |Z| \quad \text{donde} \quad Z \sim \text{Normal}(0,1).$$

- **Valor crítico** $c_\alpha = z_{1-\alpha/2}$.
- **Regla de decisión**: Si $|t_N| > z_{1-\alpha/2}$, rechazamos H_0.

Retornos de la educación (NLSY) (Blackburn y Neumark (QJE, 1992))

- ¿Cuál es el efecto de un año adicional de educación sobre los salarios?
- **Datos**: Young Men's Cohort of the National Longitudinal Survey (NLSY). 5,225 individuos fueron encuestados por primera vez en 1966 a la edad de 14-24 años y luego en intervalos de uno o dos años. La muestra utilizada incluye a los hombres entrevistados en 1980 (entre 28 y 38 años) que respondieron la pregunta sobre ingreso. Tamaño de la muestra $N = 935$.

Retornos de la educación (NLSY) (Blackburn y Neumark (QJE, 1992))

- ¿Cuál es el efecto de un año adicional de educación sobre los salarios?
- **Variables**:
  - Log del salario en 1980 (*lwage*).
  - Años de educación (*educ*).
  - IQ test score realizado en 1968 (*IQ*).
  - Años de experiencia laboral (*exper*).
  - Años de antigüedad en el empleo actual (*tenure*).
  - Dummies de está casado (*married*), vive en el sur de USA (*south*) y vive en un área urbana (*urban*).

Modelo poblacional

$$\log wage_i = \beta_0 + \beta_1 educ_i + \beta_2 exper_i + \beta_3 tenure_i + \beta_4 IQ_i + x_i'\gamma + u_i,$$

donde x_i incluye regresores adicionales.

Estimación MCO: Retornos de la educación (NLSY)

Resultados en R. Variable dependiente: log(*wage*). Errores estándar robustos.

Variable	Coef.	Error est.	t	p-valor	IC 95% inf.	IC 95% sup.
educ	0.0542	0.0073	7.4373	< 0.001	0.0399	0.0685
IQ	0.0047	0.0009	5.0530	< 0.001	0.0029	0.0065
exper	0.0142	0.0033	4.3554	< 0.001	0.0078	0.0206
tenure	0.0118	0.0026	4.6261	< 0.001	0.0068	0.0168
married	0.2082	0.0395	5.2663	< 0.001	0.1306	0.2858
south	-0.0975	0.0274	-3.5599	< 0.001	-0.1512	-0.0437
urban	0.1715	0.0267	6.4239	< 0.001	0.1191	0.2239
Constante	5.0472	0.1159	43.5563	< 0.001	4.8198	5.2746

$N = 935$, $R^2 = 0.252$. Errores estándar robustos (HC1).

Retornos de la educación (NLSY)

- Modelo poblacional

$$\log wage_i = \beta_0 + \beta_1 educ_i + \beta_2 exper_i + \beta_3 tenure_i + \beta_4 IQ_i + x_i'\gamma + u_i,$$

- **Hipótesis nula**: Un año adicional de experiencia y un año adicional de antigüedad tienen el mismo efecto sobre el salario.
  Formalmente:

$$H_0 : \beta_2 = \beta_3 \text{ ó } \beta_2 - \beta_3 = 0.$$

- **Hipótesis alternativa**: Un año adicional de experiencia y un año adicional de antigüedad tienen efectos distintos sobre el salario.
  Formalmente:

$$H_1 : \beta_2 \neq \beta_3 \text{ ó } \beta_2 - \beta_3 \neq 0.$$

Estimación MCO: Retornos de la educación (NLSY)

Matriz de varianzas y covarianzas estimada, $\widehat{\text{AVar}}(\hat{\beta}) = \hat{V}/N$ (robusta), para los coeficientes de *educ*, *IQ*, *exper* y *tenure* (variable dependiente: log(*wage*)). En R: `vcovHC(m, type = "HC1")`.

Variable	educ	IQ	exper	tenure
educ	53.110			
IQ	-3.605	0.867		
exper	10.655	-0.307	10.604	
tenure	-1.898	0.044	-2.529	6.513

Valores multiplicados por 10^6. La matriz es simétrica.

Retornos de la educación (NLSY)

- Test estadístico

$$
\begin{aligned}
t_N &= \sqrt{N}\frac{\hat{\beta}_2 - \hat{\beta}_3}{\sqrt{\hat{V}_{22} + \hat{V}_{33} - 2\hat{V}_{23}}}, \\
&= \frac{\hat{\beta}_2 - \hat{\beta}_3}{\sqrt{\widehat{\text{AVar}}(\hat{\beta}_2) + \widehat{\text{AVar}}(\hat{\beta}_3) - 2\widehat{\text{AVar}}(\hat{\beta}_2, \hat{\beta}_3)}}, \\
&= \frac{.0142 - .0118}{[(10.604 + 6.513 - 2 \times (-2.529)) \times 10^{-6}]^{\frac{1}{2}}}, \\
&= 0.505.
\end{aligned}
$$

- $|t_N| < 1.96$: No rechazamos H_0.
- p-valor $= 0.614$

Estimación MCO: Retornos de la educación (NLSY)

Test de Wald calculado en R con la fórmula de las diapositivas (variable dependiente: $\log(wage)$).

H_0	q	W_N	p-valor (χ^2_q)	$F_N = W_N/q$	p-valor (F)
$\beta_{exper} = \beta_{tenure}$	1	0.2548	0.614	0.2548	0.614

- Con una restricción, $W_N = t_N^2 = 0.505^2 = 0.255$, y el p-valor es el mismo: 0.614.

En R: una restricción lineal sobre varios parámetros

```
install.packages("car")  # una sola vez
library(car)

w <- read_dta("wage2.dta")
m_w <- lm(log(wage) ~ educ + IQ + exper + tenure + married + south + urban,
          data = w)

# H0: beta_exper = beta_tenure
linearHypothesis(m_w, "exper = tenure", vcov. = vcovHC(m_w, type = "HC1"))
linearHypothesis(m_w, "exper = tenure", vcov. = vcovHC(m_w, type = "HC1"),
                 test = "Chisq")
```

Por defecto reporta $F_N = W_N/q$ con la F de Fisher-Snedecor; con `test = "Chisq"`, W_N con la χ^2_q. Aquí ambos dan 0.255 y p-valor 0.614.

Múltiples restricciones lineales

Múltiples restricciones lineales

- **Hipótesis nula**

$$H_0 : R'\beta = \theta_0,$$

  donde R **es una matriz de** $K \times q$ con rango$(R) = q$ y θ_0 **es un vector de** $q \times 1$.

- **Hipótesis alternativa**

$$H_1 : R'\beta \neq \theta_0.$$

Múltiples restricciones lineales

- **Hipótesis nula**

$$H_0 : R'\beta = \theta_0,$$

donde R **es una matriz de** $K \times q$ con rango$(R) = q$ y θ_0 **es un vector de** $q \times 1$.

- **Hipótesis alternativa**

$$H_1 : R'\beta \neq \theta_0.$$

- **Regla de decisión**: Un estadístico T_N, un valor crítico c_α y una regla de decisión:

1. No rechazar H_0 si $T_N \leq c_\alpha$,
2. Rechazar H_0 si $T_N > c_\alpha$.

Múltiples restricciones lineales

- **Test estadístico**: Estadístico de Wald

$$W_N = N(R'\hat{\beta} - \theta_0)'(R'\hat{V}R)^{-1}(R'\hat{\beta} - \theta_0) \xrightarrow{d}_{H_0} \chi^2_q.$$

- **Demostración**: Utilizando la distribución asintótica normal y el método delta para $g(x) = R'x$:

$$\sqrt{N}(\hat{\beta} - \beta) \xrightarrow{d} \text{Normal}(0, V),$$
$$\implies \sqrt{N}(R'\hat{\beta} - R'\beta) \xrightarrow{d} \text{Normal}(0, R'VR),$$
$$\implies \sqrt{N}(R'\hat{\beta} - \theta_0) \xrightarrow[H_0]{d} \text{Normal}(0, R'VR).$$

Utilizando $\hat{V} \xrightarrow{p} V$ y el teorema de Slutsky, bajo H_0 $(R'\beta = \theta_0)$,

$$(R'\hat{V}R)^{-1/2}\sqrt{N}(R'\hat{\beta} - \theta_0) \xrightarrow[H_0]{d} \text{Normal}(0, I_q).$$

Utilizando el teorema de la función continua y que $\sum_{k=1}^{q} z_k^2 \sim \chi_q^2$ donde $z_k \sim \text{Normal}(0, 1)$ independientes,

$$W_N = N(R'\hat{\beta} - \theta_0)'(R'\hat{V}R)^{-1}(R'\hat{\beta} - \theta_0) \xrightarrow[H_0]{d} \chi_q^2.$$

Múltiples restricciones lineales

- **Test estadístico**: Estadístico de Wald

$$W_N = N(R'\hat{\beta} - \theta_0)'(R'\hat{V}R)^{-1}(R'\hat{\beta} - \theta_0) \xrightarrow{d}_{H_0} \chi^2_q.$$

- **Valor crítico** c_α: $\Pr(\chi^2_q > c_\alpha) = \alpha$ ó $\Pr(\chi^2_q \leq c_\alpha) = 1 - \alpha$.
- **Regla de decisión**: Si $W_N > c_\alpha$, rechazamos H_0.
- **p-valor**: $\Pr(\chi^2_q > W_N) = 1 - G(W_N)$ donde $G(.)$ es la función de distribución de una χ^2_q.

Múltiples restricciones lineales

- **Test estadístico**: Estadístico de Wald

$$W_N = N(R'\hat{\beta} - \theta_0)'(R'\hat{V}R)^{-1}(R'\hat{\beta} - \theta_0) \xrightarrow{d}_{H_0} \chi^2_q.$$

- El contraste con el test estadístico de Wald es **consistente**.

Múltiples restricciones lineales

- **Test estadístico**: Estadístico de Wald

$$W_N = N(R'\hat{\beta} - \theta_0)'(R'\hat{V}R)^{-1}(R'\hat{\beta} - \theta_0) \xrightarrow{d}_{H_0} \chi^2_q.$$

- El contraste con el test estadístico de Wald es **consistente**.

  Demostración

$$\begin{aligned} W_N &= N(R'\hat{\beta} - \theta_0)'(R'\hat{V}R)^{-1}(R'\hat{\beta} - \theta_0), \\ &= N(R'\hat{\beta} - R'\beta)'(R'\hat{V}R)^{-1}(R'\hat{\beta} - R'\beta) \\ &+ N(R'\beta - \theta_0)'(R'\hat{V}R)^{-1}(R'\beta - \theta_0) \\ &+ 2N^{1/2}(R'\beta - \theta_0)'(R'\hat{V}R)^{-1/2}N^{1/2}(R'\hat{V}R)^{-1/2}(R'\hat{\beta} - R'\beta). \end{aligned}$$

  Bajo H_1, el primer término $\xrightarrow{d} \chi^2_q$; el segundo crece como $N \times$ positivo y domina al tercero ($N^{1/2} \times$ positivo ó negativo $\times$ Normal$(0, I_q)$). Entonces $W_N \xrightarrow{p} \infty$ y $\Pr(W_N > c_\alpha) \to 1$.

¿Por qué no usar dos tests t?

- Ejemplo: $H_0 : \beta_1 = 0$ y $\beta_2 = 0$ vs. $H_1 : \beta_1 \neq 0$ ó $\beta_2 \neq 0$.
- Regla: rechazar si $|t_{1,N}| > 1.96$ ó $|t_{2,N}| > 1.96$, donde $t_{k,N} = \hat{\beta}_k / s.e.(\hat{\beta}_k)$.
- Supongamos que $\hat{\beta}_1$ y $\hat{\beta}_2$ son asintóticamente independientes. Entonces

$$\begin{aligned}\lim_{N\to\infty} \Pr_{H_0}(|t_{1,N}| > 1.96 \text{ ó } |t_{2,N}| > 1.96) &= 1 - \lim_{N\to\infty} \Pr_{H_0}(|t_{1,N}| \leq 1.96 \text{ y } |t_{2,N}| \leq 1.96) \\ &= 1 - \Pr(|Z_1| \leq 1.96) \times \Pr(|Z_2| \leq 1.96) \\ &= 1 - (1 - 0.05)^2 = 0.0975.\end{aligned}$$

- El tamaño del test es 9.75%, no 5%. Si $\hat{\beta}_1$ y $\hat{\beta}_2$ están correlacionados, el tamaño queda entre 5% (correlación perfecta) y 9.75% (independencia).
- El test de Wald contrasta las dos restricciones en forma conjunta, con tamaño asintótico exactamente α.

Test de Wald vs. dos tests t: el papel de la covarianza

- Para $H_0 : \beta_1 = 0$ y $\beta_2 = 0$, el estadístico de Wald se puede escribir en función de los estadísticos t individuales y de la correlación estimada entre $\hat{\beta}_1$ y $\hat{\beta}_2$, $\hat{\rho}$ (lo demuestran en la Tarea 4):

$$W_N = \frac{t_{1,N}^2 + t_{2,N}^2 - 2\hat{\rho}\, t_{1,N}\, t_{2,N}}{1 - \hat{\rho}^2} \xrightarrow[H_0]{d} \chi_2^2.$$

- Si $\hat{\rho} = 0$: $W_N = t_{1,N}^2 + t_{2,N}^2$, que se compara con 5.99, no cada t con 1.96. Dos tests t rechazan fuera de un cuadrado; el Wald, fuera de un círculo.
- Si $\hat{\rho} \neq 0$, el Wald usa la covarianza. Con $t_{1,N} = t_{2,N} = 1.5$ (ninguno significativo al 5%): $W_N = 4.5$ si $\hat{\rho} = 0$; $W_N = 45.0$ si $\hat{\rho} = -0.9$; $W_N = 2.4$ si $\hat{\rho} = 0.9$.
- Con $\hat{\rho} = -0.9$ (típico de regresores muy correlacionados positivamente), ningún coeficiente es significativo por separado, pero rechazamos que ambos sean cero.

Retornos de la educación (NLSY)

- Modelo poblacional

$$\log wage_i = \beta_0 + \beta_1 educ_i + \beta_2 exper_i + \beta_3 tenure_i + \beta_4 IQ_i + x_i'\gamma + u_i,$$

- **Hipótesis nula**: Ni la educación ni IQ tienen efecto sobre el salario.
  Formalmente:

$$H_0 : \beta_1 = 0 \text{ y } \beta_4 = 0.$$

- **Hipótesis alternativa**: Educación ó IQ tienen efecto sobre el salario (al menos uno de los dos).
  Formalmente:

$$H_1 : \beta_1 \neq 0 \text{ ó } \beta_4 \neq 0.$$

Estimación MCO: Retornos de la educación (NLSY)

Resultados en R. Variable dependiente: log(*wage*). Errores estándar robustos.

Variable	Coef.	Error est.	t	p-valor	IC 95% inf.	IC 95% sup.
educ	0.0542	0.0073	7.4373	< 0.001	0.0399	0.0685
IQ	0.0047	0.0009	5.0530	< 0.001	0.0029	0.0065
exper	0.0142	0.0033	4.3554	< 0.001	0.0078	0.0206
tenure	0.0118	0.0026	4.6261	< 0.001	0.0068	0.0168
married	0.2082	0.0395	5.2663	< 0.001	0.1306	0.2858
south	-0.0975	0.0274	-3.5599	< 0.001	-0.1512	-0.0437
urban	0.1715	0.0267	6.4239	< 0.001	0.1191	0.2239
Constante	5.0472	0.1159	43.5563	< 0.001	4.8198	5.2746

$N = 935$, $R^2 = 0.252$. Errores estándar robustos (HC1).

Estimación MCO: Retornos de la educación (NLSY)

$$\frac{R'\hat{V}R}{N} = \begin{pmatrix} \widehat{\text{AVar}}(\hat{\beta}_{educ}) & \widehat{\text{AVar}}(\hat{\beta}_{educ}, \hat{\beta}_{IQ}) \\ \widehat{\text{AVar}}(\hat{\beta}_{educ}, \hat{\beta}_{IQ}) & \widehat{\text{AVar}}(\hat{\beta}_{IQ}) \end{pmatrix}$$

$$= \begin{pmatrix} 53.110 & -3.605 \\ -3.605 & 0.867 \end{pmatrix} \times 10^{-6}$$

$$\left[\frac{R'\hat{V}R}{N}\right]^{-1} = \begin{pmatrix} 26228 & 109006 \\ 109006 & 1605875 \end{pmatrix}$$

$$W_N = (.0542 \quad .00471) \begin{pmatrix} 26228 & 109006 \\ 109006 & 1605875 \end{pmatrix} \begin{pmatrix} .0542 \\ .00471 \end{pmatrix} \approx 168.2$$

Estimación MCO: Retornos de la educación (NLSY)

Test de Wald calculado en R con la fórmula de las diapositivas (variable dependiente: $\log(wage)$).

H_0	q	W_N	p-valor (χ^2_q)	$F_N = W_N/q$	p-valor (F)
$\beta_{educ} = \beta_{IQ} = 0$	2	168.23	< 0.001	84.11	< 0.001

- $W_N = 168.2 > 5.99$, el valor crítico de una χ^2_2 al 5%: rechazamos H_0.

En R: múltiples restricciones lineales

```
# H0: beta_educ = beta_IQ = 0
linearHypothesis(m_w, c("educ = 0", "IQ = 0"),
                 vcov. = vcovHC(m_w, type = "HC1"), test = "Chisq")
```

$W_N = 168.23$. Cada restricción es un elemento del vector de texto.

- **Límite de la distribución t y la distribución F**: Se puede demostrar que

$$t_{N-K} \xrightarrow{d} Z \sim \text{Normal}(0,1),$$
$$F_{q,N-K} \xrightarrow{d} \chi^2_q/q \implies q\,F_{q,N-K} \xrightarrow{d} \chi^2_q,$$

donde t_{N-K} es una variable aleatoria con distribución t de Student con $N-K$ grados de libertad; $F_{q,N-K}$ es una variable aleatoria con distribución F de Fisher-Snedecor con q grados de libertad en el numerador y $N-K$ grados de libertad en el denominador.

Resultados reportados por R y Stata

- Para cada coeficiente, R (`coeftest`) y Stata (`reg`) reportan el **p-valor de una t de Student para el estadístico t**.
- Para restricciones lineales, R (`linearHypothesis`) y Stata (`test`) reportan un **estadístico $F_N = W_N/q$ con el p-valor de una F de Fisher-Snedecor**. Por eso las tablas de los ejemplos muestran ambas versiones.
- Estos ajustes son irrelevantes en muestras grandes: en los ejemplos, los p-valores de ambas versiones coinciden.

Relación entre el estadístico F y el estadístico de Wald

- Estadístico F:

$$F_N = \frac{(SSR_N^r - SSR_N^u)/q}{SSR_N^u/N}$$

donde SSR_N^u es la suma de los residuos al cuadrado del modelo no restringido y SSR_N^r es la suma de los residuos al cuadrado del modelo restringido.

- Se cumple que

$$F_N = W_N/q$$

únicamente si W_N utiliza el estimador de V bajo homoscedasticidad, $\hat{V} = \hat{\sigma}^2 \left(\frac{1}{N}\sum_i x_i x_i'\right)^{-1}$. Con el estimador robusto a heteroscedasticidad no se cumple, y el estadístico F_N basado en SSR no es válido bajo heteroscedasticidad.

Test de significatividad global

- Con $y_i = \beta_0 + \beta_1 x_{1i} + \cdots + \beta_{K-1} x_{K-1,i} + u_i$ (K parámetros, incluida la constante).
- **Hipótesis nula:** El modelo no tiene poder explicativo: todos los coeficientes, salvo la constante, son cero.

$$H_0 : \beta_1 = \cdots = \beta_{K-1} = 0,$$

Hipótesis alternativa

$$H_1 : \text{ Al menos un coeficiente es distinto de cero.}$$

Test de Wald con $q = K - 1$ restricciones, $R' = [0 \;\; I_{K-1}]$ (se excluye la constante) y θ_0 un vector de ceros de $(K-1) \times 1$.

- Con muestras grandes casi siempre se rechaza, así que es poco informativo.

Estimación MCO: Retornos de la educación (NLSY)

Test de significatividad global en el modelo con siete regresores ($K = 8$ parámetros, $q = K - 1 = 7$). Variable dependiente: $\log(wage)$.

H_0	q	W_N	p-valor (χ^2_q)	$F_N = W_N/q$	p-valor (F)
Todas las pendientes $= 0$	7	369.76	< 0.001	52.82	< 0.001

- Es el $F(7, 927) = 52.82$ que Stata reporta en el encabezado de `reg, robust`.
- Ojo: `summary()` en R reporta el F_N basado en SSR (44.70), que no es válido bajo heteroscedasticidad.

En R: test de significatividad global

```
# compara el modelo con el modelo que solo tiene la constante
waldtest(m_w, vcov = vcovHC(m_w, type = "HC1"))
```

$F_N = 52.82$, con la matriz robusta. `waldtest` es del paquete `lmtest`.

Restricciones no lineales

Restricciones no lineales

- **Hipótesis nula**

$$H_0 : r(\beta) = \theta_0,$$

donde r es un vector de q funciones reales $r_j : \mathbb{R}^K \to \mathbb{R}$ continuamente diferenciables, $R = \frac{\partial}{\partial \beta} r(\beta)'$ tiene rango q y θ_0 es un vector de $q \times 1$.

- **Hipótesis alternativa**

$$H_1 : r(\beta) \neq \theta_0.$$

Restricciones no lineales

- **Hipótesis nula**

$$H_0 : r(\beta) = \theta_0,$$

donde r es un vector de q funciones reales $r_j : \mathbb{R}^K \to \mathbb{R}$ continuamente diferenciables, $R = \frac{\partial}{\partial \beta} r(\beta)'$ tiene rango q y θ_0 es un vector de $q \times 1$.

- **Hipótesis alternativa**

$$H_1 : r(\beta) \neq \theta_0.$$

- **Regla de decisión**: Un estadístico T_N, un valor crítico c_α y una regla de decisión:

1. No rechazar H_0 si $T_N \leq c_\alpha$,
2. Rechazar H_0 si $T_N > c_\alpha$.

Restricciones no lineales

- **Test estadístico**: Estadístico de Wald

$$W_N = N\,(r(\hat{\beta}) - \theta_0)'(\hat{R}'\hat{V}\hat{R})^{-1}(r(\hat{\beta}) - \theta_0) \xrightarrow{d}_{H_0} \chi^2_q,$$

donde $\hat{R} = \frac{\partial}{\partial \beta} r(\hat{\beta})'$.

- **Test estadístico**: Estadístico de Wald

$$W_N = N\,(r(\hat{\beta}) - \theta_0)'(\hat{R}'\hat{V}\hat{R})^{-1}(r(\hat{\beta}) - \theta_0) \xrightarrow{d}_{H_0} \chi^2_q,$$

donde $\hat{R} = \frac{\partial}{\partial \beta} r(\hat{\beta})'$.

Demostración: Utilizando la distribución asintótica normal y el método delta para $r(x)$:

$$\begin{aligned} \sqrt{N}(\hat{\beta} - \beta) &\xrightarrow{d} \text{Normal}(0, V), \\ \implies \sqrt{N}(r(\hat{\beta}) - r(\beta)) &\xrightarrow{d} \text{Normal}(0, R'VR), \\ \implies \sqrt{N}(r(\hat{\beta}) - \theta_0) &\xrightarrow{d}_{H_0} \text{Normal}(0, R'VR). \end{aligned}$$

donde $R = \frac{\partial}{\partial \beta} r(\beta)'$. Como $\hat{\beta} \xrightarrow{p} \beta$ y la derivada es continua, $\hat{R} \xrightarrow{p} R$. Luego seguimos los mismos pasos que con restricciones lineales.

Restricciones no lineales

- **Test estadístico**: Estadístico de Wald

$$W_N = N\,(r(\hat{\beta}) - \theta_0)'(\hat{R}'\hat{V}\hat{R})^{-1}(r(\hat{\beta}) - \theta_0) \xrightarrow{d}_{H_0} \chi^2_q,$$

  donde $\hat{R} = \frac{\partial}{\partial \beta} r(\hat{\beta})'$.
- **Valor crítico** c_α: $\Pr(\chi^2_q > c_\alpha) = \alpha$ ó $\Pr(\chi^2_q \leq c_\alpha) = 1 - \alpha$.
- **Regla de decisión**: Si $W_N > c_\alpha$, rechazamos H_0.

Restricciones no lineales

- El test t y el test de Wald funcionan bien para hipótesis lineales pero tienen problemas para hipótesis no lineales

  Ambos tests no son invariantes a cómo formulamos H_0.

  Ejemplo: $H_0 : \beta_1 = 1$ y $H_0 : 1/\beta_1 = 1$ son la misma hipótesis.

  - Con $r(\beta) = \beta_1$: $W_N^{(1)} = N\dfrac{(\hat{\beta}_1 - 1)^2}{\hat{v}_{11}}$.
  - Con $r(\beta) = 1/\beta_1$: $\hat{R} = -1/\hat{\beta}_1^2$, entonces $W_N^{(2)} = N\dfrac{(1/\hat{\beta}_1 - 1)^2}{\hat{v}_{11}/\hat{\beta}_1^4} = \hat{\beta}_1^2\, W_N^{(1)}$.
  - Si $\hat{\beta}_1 = 1.5$ y $W_N^{(1)} = 3$, entonces $W_N^{(2)} = 6.75$: al 5% ($c_\alpha = 3.84$) la primera formulación no rechaza H_0 y la segunda sí.

Efectos de la contaminación en los precios de las viviendas (Harrison y Rubinfeld (JEEM, 1978))

- ¿Cuál es el efecto de una mayor concentración de óxidos de nitrógeno en el aire en el precio de las viviendas?
- Modelo

$$\log(price_i) = \beta_0 + \beta_{lnox} \log(nox_i) + \beta_{rooms} rooms_i + \beta_{stratio} stratio_i + u_i,$$

donde *price* es el precio de la vivienda, *nox* es la concentración de óxidos de nitrógeno en el aire (contaminación), *rooms* es el número de habitaciones y *stratio* es el ratio estudiante/profesor en la comunidad.

Estimación MCO: Efectos de la contaminación en los precios de las viviendas

Resultados en R: `lm(log(price) ~ log(nox) + rooms + stratio)`. Variable dependiente: log(*price*). Errores estándar robustos.

Variable	Coef.	Error est.	t	p-valor	IC 95% inf.	IC 95% sup.
log(nox)	-0.6453	0.0602	-10.7274	< 0.001	-0.7635	-0.5271
rooms	0.2567	0.0254	10.1096	< 0.001	0.2068	0.3066
stratio	-0.0509	0.0048	-10.6211	< 0.001	-0.0603	-0.0415
Constante	10.3595	0.2628	39.4259	< 0.001	9.8432	10.8757

$N = 506$, $R^2 = 0.576$. Errores estándar robustos (HC1).

- Una habitación más aumenta el precio en aproximadamente 25.7%. El cambio exacto (clase 4) es $(\exp(\beta_{rooms}) - 1) \times 100$.

Efectos de la contaminación en los precios de las viviendas (Harrison y Rubinfeld (JEEM, 1978))

- **Hipótesis nula**

$$H_0 : (\exp(\beta_{rooms}) - 1) \times 100 = 0.$$

- **Hipótesis alternativa**

$$H_1 : (\exp(\beta_{rooms}) - 1) \times 100 \neq 0.$$

- $r(\hat{\beta}) = (\exp(\hat{\beta}_{rooms}) - 1) \times 100 = 29.3$
- $\hat{R} = \exp(\hat{\beta}_{rooms}) \times 100$
- $\frac{1}{N}\hat{R}'\hat{V}\hat{R} = \exp(\hat{\beta}_{rooms})100 \times \widehat{\text{AVar}}(\hat{\beta}_{rooms}) \times \exp(\hat{\beta}_{rooms})100 = 10.8$
- $W_N = N\frac{r(\hat{\beta})^2}{\hat{R}'\hat{V}\hat{R}} = \frac{29.3^2}{10.8} = 79.5$

Estimación MCO: Efectos de la contaminación en los precios de las viviendas

Método delta calculado en R con las fórmulas de las diapositivas (variable dependiente: $\log(price)$).

	Estimador	Error est.	z	p-valor	IC 95% inf.	IC 95% sup.
$(\exp(\beta_{rooms}) - 1) \times 100$	29.269	3.283	8.916	< 0.001	22.835	35.703

- $W_N = z^2 = 8.916^2 = 79.5$: rechazamos H_0.

En R: método delta

```
h <- read_dta("hprice2.dta")
m_h <- lm(log(price) ~ log(nox) + rooms + stratio, data = h)

# estimador, error estandar e IC de una funcion de los coeficientes
deltaMethod(m_h, "(exp(rooms) - 1) * 100", vcov. = vcovHC(m_h, type = "HC1"))
```

Estimador 29.269, error estándar 3.283 e IC [22.835, 35.703], como en la tabla. `deltaMethod` es del paquete `car`.

El test de Wald no es invariante a cómo formulamos H_0

- $(\exp(\beta_{rooms}) - 1) \times 100 = 0$ si y sólo si $\beta_{rooms} = 0$: es la misma hipótesis.
- Pero el estadístico de Wald cambia con la formulación:

H_0	W_N	p-valor (χ^2_1)
$\beta_{rooms} = 0$	102.2	< 0.001
$(\exp(\beta_{rooms}) - 1) \times 100 = 0$	79.5	< 0.001

- Aquí ambas formulaciones rechazan H_0, pero con estadísticos más cercanos al valor crítico pueden llevar a conclusiones distintas.
- Conviene formular H_0 de la forma más lineal posible.