

Análisis Econométrico

Servicio militar e ingresos:

regresión simple, múltiple y sesgo de variable omitida

Ramiro de Elejalde

Facultad de Economía y Finanzas
Universidad Alberto Hurtado

La pregunta y los datos

Regresión simple

Regresión múltiple y sesgo de variable omitida

Efectos distintos por raza

Cierre

Referencias: Angrist (1998, Econometrica); cap. 3.3.1 de Angrist y Pischke; clase 4 (Estimación por MCO), sección de sesgo de variable omitida.

La pregunta y los datos

¿Sirve el servicio militar para ganar más?

- **Pregunta:** ¿Cuál es el efecto de servir en las fuerzas armadas sobre los ingresos posteriores de un solicitante?
- Es una pregunta de política: el reclutamiento voluntario cuesta recursos públicos y los solicitantes deciden si ingresan o no.
- Comparar los ingresos de veteranos y no veteranos es lo obvio. Pero la comparación mezcla el efecto del servicio con las diferencias previas entre quienes ingresan y quienes no.
- **El problema:** el servicio militar no se asigna al azar. Nunca observamos al mismo solicitante como veterano y como no veterano.

Los datos: solicitantes a las fuerzas armadas (Angrist 1998)

- **Población:** hombres que solicitaron ingresar a las fuerzas armadas de EE.UU. entre 1979 y 1982.
- **Ingresos:** promedio 1988–1991 de los ingresos gravables de seguridad social (*earnings*, en US\$).
- **Tratamiento:** $d_{vet_i} = 1$ si el solicitante ingresó (veterano), 0 si no.
- **Covariables:** raza ($dnwhite_i = 1$ si no es blanco), grupo de puntaje en el test de aptitud de las fuerzas armadas (AFQT), grupo de escolaridad al solicitar, año de nacimiento y año de solicitud.
- **Unidad de observación:** una *celda* de solicitantes con las mismas covariables ($N = 7,904$ celdas). **Simplificación:** aquí todas las celdas pesan lo mismo, de modo que las magnitudes difieren de las de Angrist (que pondera por el tamaño de la celda).

Variable	Blancos, no vet.	Blancos, vet.	No blancos, no vet.	No blancos, vet.
Celdas	2,180	1,868	2,092	1,764
Ingreso promedio 1988-91 (US\$)	13,038	13,824	10,765	12,181
% en grupo AFQT 2	19.6	12.0	21.0	12.9
% en grupo AFQT 3	19.1	18.0	20.1	18.1
% en grupo AFQT 4	20.2	22.1	20.8	22.4
% en grupo AFQT 5	20.6	24.0	21.0	24.5
% en grupo AFQT 6	20.6	24.0	17.0	22.0

Los veteranos ganan más, **pero también tienen mayor puntaje AFQT**: las fuerzas armadas seleccionan a los solicitantes según su puntaje y su escolaridad.

- El modelo de interés

$$earnings_i = \beta_0 + \beta_1 dvet_i + u_i$$

donde u_i contiene todos los factores que influyen sobre los ingresos además de ser veterano.

- β_1 es el efecto causal del servicio militar si $\mathbb{E}(u_i | dvet_i) = 0$.
- Como $dvet_i$ es binaria, $\beta_1 = \mathbb{E}(earnings_i | dvet_i = 1) - \mathbb{E}(earnings_i | dvet_i = 0)$.
- Si la selección de las fuerzas armadas depende de variables que observamos x_i (AFQT, escolaridad, edad), podemos aspirar a la **asignación aleatoria condicional en observables**:

$$earnings_i = \beta_0 + \beta_1 dvet_i + \gamma' x_i + v_i, \quad \mathbb{E}(v_i | dvet_i, x_i) = 0.$$

Regresión simple

Regresión simple: earnings sobre dvet

Errores estándar robustos entre paréntesis.

	Todos	Blancos	No blancos
Constante	11,924.8 (55.0)	13,037.6 (73.2)	10,765.3 (74.5)
Veterano	1,101.5 (72.1)	786.9 (96.3)	1,415.8 (97.7)
N	7,904	4,048	3,856
R^2	0.028	0.016	0.050

- El coeficiente de *dvet* es la **diferencia de medias** entre veteranos y no veteranos: US\$787 entre los blancos (13,824 – 13,038) y US\$1,416 entre los no blancos.
- ¿Es este el efecto causal del servicio militar?

¿Cuándo es causal la diferencia de medias?

- Solo si $Cov(u_i, dvet_i) = 0$: veteranos y no veteranos no difieren en otros factores que afecten los ingresos.
- La tabla de descriptivas sugiere que no se cumple: **los veteranos tienen mayor puntaje AFQT**, y el puntaje AFQT probablemente aumenta los ingresos por sí mismo.
- Angrist y Pischke (cap. 3.3.1) explican por qué: las fuerzas armadas solo aceptan, en su mayoría, a graduados de secundaria con puntajes en la mitad superior. Esa selección positiva genera un **sesgo positivo** en la comparación simple.

Lo que sigue: agregar el AFQT y la escolaridad como controles, y ver cuánto se mueve $\hat{\beta}_1$.

Regresión múltiple y sesgo de variable omitida


Regresión múltiple: agregando controles

Variable dependiente: *earnings*. Coeficiente de *dvet*, con errores estándar robustos entre paréntesis.

	(1)	(2)	(3)	(4)	(5)	(6)
Veterano, blancos	786.9 (96.3)	528.4 (89.1)	779.8 (70.8)	508.3 (59.4)	444.7 (55.5)	344.2 (42.5)
Veterano, no blancos	1,415.8 (97.7)	1,198.2 (94.0)	1,292.4 (63.5)	1,080.7 (56.9)	1,027.8 (55.3)	1,057.9 (43.3)
Grupo AFQT		✓		✓	✓	✓
Escolaridad			✓	✓	✓	✓
Año de nacimiento y de solicitud					✓	✓
Celda de covariables						✓

- **Signo del sesgo de variable omitida:** ¿omitir el AFQT sobrestima o subestima el efecto?

El mismo resultado en un gráfico



Efecto estimado de *dvet* con intervalo de confianza de 95% en las seis especificaciones de la tabla.

El signo del sesgo

- Con una variable omitida x_{2i} (el AFQT), el sesgo asintótico del coeficiente de la regresión simple es

$$\text{Sesgo}(\hat{\gamma}_1) = \beta_2 \frac{\text{Cov}(d\text{vet}_i, x_{2i})}{\text{Var}(d\text{vet}_i)}.$$

El signo del sesgo

- Con una variable omitida x_{2i} (el AFQT), el sesgo asintótico del coeficiente de la regresión simple es

$$\text{Sesgo}(\hat{\gamma}_1) = \beta_2 \frac{\text{Cov}(d\text{vet}_i, x_{2i})}{\text{Var}(d\text{vet}_i)}.$$

- Los coeficientes de los grupos AFQT son positivos y crecientes ($\beta_2 > 0$) y los veteranos tienen mayor puntaje ($\text{Cov}(d\text{vet}_i, x_{2i}) > 0$).

El signo del sesgo

- Con una variable omitida x_{2i} (el AFQT), el sesgo asintótico del coeficiente de la regresión simple es

$$\text{Sesgo}(\hat{\gamma}_1) = \beta_2 \frac{\text{Cov}(d\text{vet}_i, x_{2i})}{\text{Var}(d\text{vet}_i)}.$$

- Los coeficientes de los grupos AFQT son positivos y crecientes ($\beta_2 > 0$) y los veteranos tienen mayor puntaje ($\text{Cov}(d\text{vet}_i, x_{2i}) > 0$).
- El sesgo es positivo: la regresión simple sobrestima el efecto del servicio militar.
- Con AFQT y escolaridad, el efecto estimado cae de 787 a 508 para blancos (35%) y de 1,416 a 1,081 para no blancos (24%).

Descomposición del sesgo

- Sea $\hat{\gamma}_1$ el coeficiente de $dvet$ en la regresión simple y $\hat{\beta}_1$ en la regresión con controles z_{ji} (dummies de AFQT y escolaridad). En la muestra

$$\hat{\gamma}_1 = \hat{\beta}_1 + \sum_j \hat{\beta}_j \hat{\delta}_j,$$

donde $\hat{\beta}_j$ es el coeficiente de z_{ji} en la regresión con controles y $\hat{\delta}_j$ es el coeficiente de $dvet_i$ en la regresión de z_{ji} sobre $dvet_i$.

- Cada término $\hat{\beta}_j \hat{\delta}_j$ es lo que aporta la variable omitida j al sesgo.

Grupo	Regresión simple	Con controles	Sesgo	Aporte AFQT	Aporte escolaridad
Blancos	786.9	508.3	278.6	256.5	22.2
No blancos	1,415.8	1,080.7	335.1	206.1	129.0

Para blancos casi todo el sesgo viene del AFQT. Para no blancos, también aporta la escolaridad.

Más controles, menos sesgo (pero no cero)

- Las columnas (5) y (6) agregan cohorte, año de solicitud y una dummy por cada celda de covariables: el efecto para blancos baja a 344; para no blancos queda en torno a 1,050.
- **Un solo sentido:** que el coeficiente se mueva al agregar controles es mala señal para la regresión simple. Que deje de moverse *no prueba* que ya no haya sesgo: pueden quedar variables omitidas que no observamos (motivación, salud, alternativas laborales).
- El argumento de Angrist es que las fuerzas armadas seleccionan, sobre todo, con variables que sí observamos (edad, escolaridad, puntaje AFQT). *Eso es una hipótesis sobre el proceso de selección, no algo que la regresión verifique.*

Efectos distintos por raza

Interacción entre dummies

- Un solo modelo con interacción entre $dvet$ y $dnwhite$

$$\mathbb{E}(\text{earnings}|dvet, dnwhite) = \beta_0 + \beta_{dvet} dvet + \beta_{dnwhite} dnwhite + \beta_{dvet_dnwhite} dvet \times dnwhite.$$

- Estimación: $\hat{\beta}_{dvet} = 787$, $\hat{\beta}_{dnwhite} = -2,272$ y $\hat{\beta}_{dvet_dnwhite} = 629$, con $\mathbb{E}(\text{earnings}) = 12,431$.
- El efecto de $dvet$ es $\beta_{dvet} = 787$ para blancos y $\beta_{dvet} + \beta_{dvet_dnwhite} = 1,416$ para no blancos: los mismos números de la regresión simple por raza.
- ¿Qué mide $\beta_{dnwhite}$? ¿Y $\beta_{dvet_dnwhite}$?

Cierre

- La regresión simple con una dummy es una diferencia de medias. Es causal solo si veteranos y no veteranos son comparables.
- Aquí no lo son: **selección positiva** (mayor AFQT) $\Rightarrow$ sesgo positivo de variable omitida.
- Agregar controles reduce el efecto estimado (35% para blancos y 24% para no blancos con AFQT y escolaridad), en la dirección que predice el signo del sesgo.
- La descomposición $\hat{\gamma}_1 = \hat{\beta}_1 + \sum_j \hat{\beta}_j \hat{\delta}_j$ dice cuánto aporta cada variable omitida.
- Angrist y Pischke (2009) reportan con las celdas ponderadas por su tamaño: entre los blancos la diferencia de US\$1,233 se vuelve negativa al controlar por covariables, y entre los no blancos baja de US\$2,449 a US\$840. **Las magnitudes cambian con la ponderación; el signo del sesgo y la lección no.**

- ¿Por qué el AFQT es la variable omitida más importante para los blancos? ¿Qué otras variables no observadas podrían sesgar el resultado y en qué dirección?
- Si los solicitantes más motivados son los que ingresan y también los que más ganan, ¿qué signo tendría ese sesgo?
- ¿Qué pasaría con la regresión simple si las fuerzas armadas aceptaran a los solicitantes por sorteo?

- Todo lo que aparece en estas diapositivas se genera con un script de R:

`examples/4.MCO_estimacion_veteranos-angrist`

- **Fuente:**

- Angrist, J. (1998), “Estimating the Labor Market Impact of Voluntary Military Service Using Social Security Data on Military Applicants”, *Econometrica* 66(2): 249–288.
- Angrist, J. y J.-S. Pischke (2009), *Mostly Harmless Econometrics*, cap. 3.3.1.