

Análisis Económico

Ayudantía 5

Magíster en Economía, Universidad Alberto Hurtado

Temas: primeros pasos en R. Importar datos, crear variables, estadísticas descriptivas, gráficos, regresión simple y múltiple por MCO, y tablas de resultados.

En esta ayudantía el ayudante escribe y corre el código en pantalla, ejercicio por ejercicio; no hace falta traer computador. En cada parte se indican entre corchetes las funciones de R que se usan. Los ejercicios 1 a 6 son los de la sesión (80 minutos); el 7 queda como práctica adicional.

Si quiere replicarlo en su computador

Si quiere, puede replicar todo en su computador, durante la ayudantía o después. El script completo, TA5.R, y los datos están en el repositorio del curso. Esto es lo que tiene que hacer:

1. Instale R y RStudio. Si no puede instalarlos, cree una cuenta gratuita en Posit Cloud, que corre RStudio en el navegador: *New Project* → *New Project from Git Repository* y pegue https://github.com/ramirode/econometria_mae.git.

2. Abra RStudio y corra en la consola (una sola vez; tarda varios minutos):

```
install.packages(c("tidyverse", "haven", "sandwich",  
                  "modelsummary", "kableExtra"))
```

3. Cree una carpeta TA5 con dos subcarpetas, `code` e `input`. Guarde el script TA5.R en `code` y los datos `ch8_cps.dta` en `input`. Ambos archivos están en el repositorio del curso, en TA/TA5. En Posit Cloud la carpeta ya existe: `/cloud/project/TA/TA5`.
4. Abra TA5.R y cambie la línea `dir_proyecto <- "..."` por la ruta a su carpeta TA5. Es lo único que hay que modificar.

Los datos

El archivo `ch8_cps.dta` contiene datos de trabajadores de tiempo completo de entre 21 y 64 años encuestados en la *Current Population Survey* de EEUU de marzo de 2005. Las variables son:

- `ahe`: salario promedio por hora en 2004 (en dólares),

- `yrseduc`: años de educación,
- `female`: igual a 1 si la persona es mujer,
- `age`: edad en años,
- `northeast`, `midwest`, `south`, `west`: dummies de región.

Ejercicios

1. *Importar e inspeccionar los datos.*

- a) Fije la carpeta de trabajo en `TA5` y cargue los paquetes. `[setwd, library]`
- b) Importe los datos y guárdelos en un objeto llamado `d`. `[read_dta]`
- c) ¿Cuántas observaciones y cuántas variables tiene la base? ¿Qué es una observación? `[nrow, ncol, names, head, glimpse]`
- d) Revise el mínimo, la media y el máximo de cada variable. ¿Hay valores faltantes o valores que le llamen la atención? `[summary]`

2. *Crear variables.*

- a) Cree la variable `lahe`, el logaritmo natural de `ahe`. `[mutate, log]`
- b) Cree la variable `sexo`, igual a "Mujer" si `female` es 1 y a "Hombre" si es 0. Verifique que quedó bien construida. `[if_else, count]`

3. *Estadísticas descriptivas.*

- a) Calcule la media y la desviación estándar de `ahe`, `lahe`, `yrseduc`, `age` y `female`. ¿Cómo se interpreta la media de `female`? `[summarise, mean, sd]`
- b) Calcule el número de observaciones y las medias de `ahe`, `yrseduc` y `age` por separado para hombres y mujeres. ¿Cuál es la brecha de salarios entre hombres y mujeres, en porcentaje? ¿Quiénes tienen más educación? `[group_by, n]`
- c) Construya una tabla de frecuencias de `yrseduc`. ¿Cuáles son los niveles de educación más frecuentes? `[count]`

4. *Gráficos.*

- a) Grafique un histograma de `ahe` y otro de `lahe`. Describa la forma de cada distribución. `[ggplot, geom_histogram]`
- b) Compare la distribución de `lahe` de hombres y mujeres con un diagrama de caja. `[geom_boxplot]`
- c) Calcule la media de `lahe` para cada valor de `yrseduc` y grafíquela contra `yrseduc`. ¿Qué objeto poblacional está estimando? ¿Le parece aproximadamente lineal? `[group_by, geom_point]`

- d) Guarde los gráficos como imágenes en una carpeta `output`. [`dir.create`, `ggsave`]

5. *Regresión simple*. Considere el modelo

$$lahe_i = \beta_0 + \beta_1 yrseduc_i + u_i.$$

- a) Estime el modelo por MCO. Interprete $\hat{\beta}_1$. [`lm`, `summary`, `coef`]
- b) Calcule los errores estándar robustos a heterocedasticidad y compárelos con los que reporta `summary`. [`vcovHC`, `diag`, `sqrt`]
- c) Verifique que $\hat{\beta}_1$ es igual a la covarianza muestral entre `yrseduc` y `lahe` dividida por la varianza muestral de `yrseduc`, y que $\hat{\beta}_0 = \overline{lahe} - \hat{\beta}_1 \overline{yrseduc}$. [`cov`, `var`]
- d) Guarde los valores predichos y los residuos como variables nuevas. Verifique que los residuos tienen media cero y covarianza cero con `yrseduc`. ¿Por qué se cumple esto siempre? [`fitted`, `resid`]
- e) Agregue la recta de regresión al gráfico del ejercicio 4(c). ¿Qué log salario predice el modelo para una persona con 12 años de educación? ¿Y con 16? [`geom_smooth`, `predict`]

6. *Regresión múltiple y tabla de resultados*. Considere los modelos

$$lahe_i = \beta_0 + \beta_1 yrseduc_i + \beta_2 female_i + u_i,$$

$$lahe_i = \beta_0 + \beta_1 yrseduc_i + \beta_2 female_i + \beta_3 age_i + u_i.$$

- a) Estime los dos modelos. Interprete $\hat{\beta}_2$ y compárelo con la brecha de salarios del ejercicio 3(b). [`lm`]
- b) El coeficiente de `yrseduc`, ¿aumenta o disminuye al agregar `female`? Explique el signo del cambio con la fórmula del sesgo de variable omitida y verifique que la fórmula se cumple exactamente en la muestra.
- c) Arme una tabla con los tres modelos (el del ejercicio 5 y estos dos), con errores estándar robustos, y guárdela en `output`. [`list`, `modelsummary`]
- d) ¿Cree que $\hat{\beta}_1$ mide el efecto causal de un año más de educación sobre el salario? Mencione una variable omitida y el signo del sesgo que genera.

Práctica adicional

7. *MCO con matrices y regresiones por sexo*. Sea $\mathbf{X}$ la matriz de $N \times 4$ cuyas columnas son un vector de unos, `yrseduc`, `female` y `age`, y sea $\mathbf{y}$ el vector de `lahe`.

- a) Calcule $\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$ y verifique que coincide con el resultado de `lm`. [`cbind`, `t`, `%*%`, `solve`]
- b) Estime la regresión simple del ejercicio 5 por separado para hombres y para mujeres. ¿Para quiénes es mayor el retorno a la educación? [`filter`]